



中国科学院大学
University of Chinese Academy of Sciences

硕士学位论文

基于磁共振物理模型和深度学习的快速成像方法

作者姓名： 胡晨

指导教师： 王珊珊 研究员 中国科学院深圳先进技术研究院

王海峰 副研究员 中国科学院深圳先进技术研究院

学位类别： 工程硕士

学科专业： 电子与通信工程

培养单位： 中国科学院深圳先进技术研究院

2022 年 6 月

Fast Imaging Method Based on Magnetic Resonance Physical
Model and Deep Learning

A thesis submitted to
University of Chinese Academy of Sciences
in partial fulfillment of the requirement
for the degree of
Master of Engineering
in Electronics and Communication Engineering

By

Chen Hu

Supervisor: Research Fellow Shanshan Wang

Associate Research Fellow Haifeng Wang

Shenzhen Institutes of Advanced Technology

Chinese Academy of Sciences

June 2022

摘 要

磁共振成像是一种广泛应用于临床诊断和治疗中的成像技术，其具有无创、无辐射以及软组织对比度高的特点。然而，其固有、缓慢的成像过程限制了其更为广泛的应用。实现快速磁共振成像的一种常用方法是：先对磁共振数据以一个较高的欠采样率进行采样，之后通过图像处理等技术进行重建，恢复出高质量的图像。

目前深度学习在磁共振图像重建任务中取得了令人鼓舞的效果，然而，大部分基于深度学习的重建方法都是直接训练一个深度神经网络去拟合从欠采样数据到全采样数据的非线性映射函数，而没有考虑到利用磁共振物理模型去进行图像重建。因此，本文对基于磁共振物理模型和深度学习的快速成像方法展开研究，主要完成了以下工作：

1. 本文提出了一种将广义交替投影算法与深度学习结合的重建方法。通过将算法迭代求解步骤中的非线性图像稀疏变换域替换为卷积神经网络，迭代步长以及收缩阈值替换为可学习参数实现算法与深度学习的结合。在内部磁共振数据集上进行了验证，实验结果表明该方法能够实现优于对比方法的图像重建质量。

2. 本文利用磁共振数据的特性，提出了一种基于自监督学习的磁共振图像重建框架。通过从二次欠采样数据子集恢复欠采样 k 空间数据的方式促进网络学习恢复频率信息的能力，通过构建并行网络框架以及差异损失项的定义来间接约束网络在未扫描频率点处信息恢复的正确性。在开源数据集上的实验结果表明，所提自监督重建方法能够实现与对应基于监督学习的重建方法相当的重建性能。

关键词：快速磁共振成像，图像重建，磁共振物理模型，深度学习

Abstract

Magnetic resonance imaging (MRI) with non-invasive, non-radiation and high soft tissue contrast, is a kind of imaging technology widely used in clinical diagnosis and treatment. However, its inherent and slow imaging process limits its wider application. A common method to realize fast MRI is to sample magnetic resonance (MR) data with a high undersampling rate, and then reconstruct the high-quality image by image processing technology.

Recently, deep learning has achieved inspired results in MR image reconstruction tasks. However, most reconstruction methods based on deep learning are directly training a deep neural network to fit the nonlinear mapping function from undersampled data to fully-sampled data, without considering the use of MR physical model for image reconstruction. Therefore, this paper studies the fast imaging method based on MR physical model and deep learning, and mainly completes the following projects:

1. In this paper, a reconstruction method combining generalized alternating projection (GAP) algorithm with deep learning is proposed. The combination of the algorithm and deep learning is realized by replacing the nonlinear image sparse transform domain with convolutional neural network (CNN) and replacing the iterative step and shrinkage-thresholding with learnable parameters. Validation is performed on an internal MR dataset, the experimental results show that the proposed method can achieve better image reconstruction quality than the comparison methods.

2. In this paper, a MR image reconstruction framework based on self-supervised learning is proposed utilizing the properties of MR data. The ability of network learning to recover frequency information is promoted by recovering undersampled k-space data from the subsets of the data. The correctness of information recovery at the unscanned frequency points is indirectly constrained by the construction of parallel network framework and the definition of the difference loss term. Experimental results on an open source dataset show that the proposed self-supervised reconstruction method can

achieve the same reconstruction performance as the corresponding reconstruction method based on supervised learning.

Keywords: Fast MRI, Image Reconstruction, MR Physical Model, Deep Learning

目 录

第 1 章 绪论.....	1
1.1 课题研究的背景和意义	1
1.2 国内外研究现状	4
1.3 本文主要研究内容和创新点	7
1.4 论文内容安排	8
第 2 章 磁共振重建基础理论	11
2.1 磁共振成像原理	11
2.2 压缩感知磁共振成像	13
2.2.1 压缩感知理论	14
2.2.2 压缩感知磁共振成像模型	15
2.3 基于深度学习的磁共振重建方法	16
2.3.1 基于非迭代展开网络的重建方法	17
2.3.2 基于迭代展开网络的重建方法	19
2.4 本章小结	21
第 3 章 GAP 算法与深度学习结合的重建方法	23
3.1 引言	23
3.2 方法论	24
3.2.1 GAP 算法求解重建逆问题	24
3.2.2 GAP-Net 网络框架	26
3.2.3 实现细节	27
3.3 实验结果与分析	28
3.4 本章小结	31
第 4 章 基于自监督学习的 MRI 重建方法	33
4.1 引言	33
4.2 方法论	34
4.2.1 ISTA-Net 概述	34

4.2.2 自监督学习框架.....	36
4.2.3 实现细节.....	38
4.3 实验结果与分析.....	39
4.4 本章小结.....	42
第 5 章 总结与展望	43
5.1 工作总结.....	43
5.2 工作展望.....	44
参考文献.....	45
致 谢.....	51
作者简历及攻读学位期间发表的学术论文与研究成果	53

图表目录

图 1.1	实现快速 MRI 的几种方法。	3
图 2.1	进动。	12
图 2.2	k 空间与图像域的对应关系(Hamilton et al., 2017)。	13
图 2.3	U-Net 应用于 MRI 重建中的网络结构图(Zbontar et al., 2018)。	17
图 2.4	KIKI-Net 数据流和中间操作框图(Eo et al., 2018)。	18
图 2.5	ADMM-Net 的数据流图(Sun et al., 2016)。	20
图 2.6	MoDL 网络结构框图(Aggarwal et al., 2018)。	21
图 3.1	GAP-Net 整体网络框图。	26
图 3.2	GAP-Net 第 t 个迭代重建网络结构图。	27
图 3.3	GAP-Net 在不同欠采样率下的定性分析。	29
图 4.1	ISTA-Net ⁺ 第 k 个迭代步骤的网络结构图(Zhang and Ghanem, 2018)。	35
图 4.2	所提自监督 MRI 重建框架图。	36
图 4.3	两个子集的构造。	38
图 4.4	所提自监督重建方法在 8 倍欠采样率下的网络损失曲线。	39
图 4.5	不同方法在 4 倍和 8 倍欠采样率下的实例重建结果及误差图。	41
表 3.1	GAP-Net 在不同欠采样率下的定量分析。	29
表 3.2	不同方法在 8 倍欠采样率下的定量分析。	30
表 4.1	不同重建方法在 4 倍和 8 倍欠采样率下的定量分析。	40
表 4.2	4 倍与 8 倍欠采样率下的消融实验结果。	42

符号列表

缩写

MRI	Magnetic Resonance Imaging
RF	Radio Frequency
MR	Magnetic Resonance
pMRI	parallel MRI
CS	Compressed Sensing
DL	Deep Learning
RIP	Restricted Isometric Property
DWT	Discrete Wavelet Transform
TV	Total Variation
CNN	Convolutional Neural Network
PFI	Partial Fourier Transform
ACS	Autocalibration Signals
SVD	Singular Value Decomposition
DCT	Discrete Cosine Transform
ADMM	Alternating Direction Multiplier Method
ISTA	Iterative Shrinkage-Thresholding Algorithm
GAP	Generalized Alternating Projection
FID	Free Induction Decay
CG	Conjugate Gradient
WT	Wavelet Transform
MSE	Mean Square Error
NMSE	Normalized Mean Square Error
PSNR	Peak Signal to Noise Ratio
SSIM	Structural Similarity Index Measure

第1章 绪论

1.1 课题研究的背景和意义

磁共振成像 (Magnetic Resonance Imaging, MRI) 是一种用以诊断和研究人体多种疾病的不可或缺的工具, 其在成像过程中通过施加静磁场、梯度磁场以及特定频率的射频 (Radio Frequency, RF) 脉冲磁场, 从而使得成像对象产生与空间位置相依赖的磁共振 (Magnetic Resonance, MR) 信号, 该信号被信号采集线圈所收集并通过傅里叶变换等技术进行解码最终呈现出成像对象整个三维空间的组织结构信息。与其他成像技术 (如计算机断层成像) 相比, MRI 具有无创、无辐射以及软组织对比度高的特点, 并且可以实现多参数、多功能、多角度成像, 因此, 被广泛应用于临床诊断与治疗中。

然而, 由于 MR 信号的采集是顺序的, 而信号的采集速度又受限于成像对象生理上或者成像设备物理上的约束, 导致 MR 原始数据的采集过程变得十分缓慢。长时间的扫描过程不仅会增加病人的不适感, 而且扫描对象也可能会发生位置的变动, 导致运动伪影的产生, 这些伪影通常会与病理特征相混淆, 从而影响医学诊断结果, 因此难以实现一些实时性要求较高的成像任务, 例如心脏、灌注和功能成像等。自 20 世纪 80 年代 MRI 应用于临床研究以来, 该问题就一直困扰着人们, 因此, 如何实现快速成像一直都是 MRI 领域中的一个重要课题。如图 1.1 所示, 目前解决扫描时间长, 实现快速 MRI 的研究工作大致可以分为以下三类: 1) 基于物理方法的快速扫描序列(黄佳佳, 2014), 该方法通过设计特定的磁共振 RF 脉冲序列以实现扫描时间的缩短。例如 EPI 序列(Edelman et al., 1994)、FSE 序列(Listerud et al., 1992)以及 FLASH/MPRAGE 序列(Kaiser and Zeitler, 1989)等; 2) 基于硬件系统的并行成像技术 (parallel MRI, pMRI) (张久明, 2014), 其通过使用多个射频线圈并行收集成像对象不同区域的信号来加速 MR 原始数据的采集过程, 但是由于物理空间上的约束, 射频线圈的数量不能无上限的增加, 并且, 多个线圈之间会产生互相干扰, 这也为后续的信号处理增加了一定的难度。其中, 典型的并行成像方法有 SENSE(Pruessmann et al., 1999)、GRAPPA(Griswold et al., 2002)以及 SPIRiT(Lustig and Pauly, 2010)等; 3) 基于 k 空间欠采样技术(王

水花 and 张煜东, 2015), 该类方法通过以一个较高的欠采样率对 MR 原始数据进行采样以实现信号采集过程的加速。通常, 采用的欠采样率会超出奈奎斯特采样定理的限制, 而这会导致图像上产生一定的伪影以及噪声放大的情况, 所以在此类快速 MRI 技术之后需要通过一定的图像重建技术恢复出高质量的图像。

典型的图像重建方法包括基于压缩感知 (Compressed Sensing, CS) 算法 (Donoho, 2006) 的 MRI 重建方法 (CS-MRI) (Lustig et al., 2007) 以及基于深度学习 (Deep Learning, DL) 的 MRI 重建方法 (DL-MRI) (Wang et al., 2016)。其中 CS-MRI 要求图像具有稀疏性或者在某个变换域具有稀疏性, 欠采样矩阵满足有限等距特性 (Restricted Isometric Property, RIP) 的条件下, 通过非线性重建出来的图像可以满足与采样到的原始 k 空间数据的一致性约束与图像的稀疏性约束。该类方法从 MR 物理模型出发, 通过算法进行求解, 具有较强的数学可解释性, 然而其迭代过程相对较长, 计算复杂度较高, 且部分参数需要事先经验性的设置。CS-MRI 中典型的方法有离散小波变换 (Discrete Wavelet Transform, DWT) (Lai et al., 2016, Qu et al., 2012, Zhu et al., 2013)、总变分 (Total Variation, TV) (Block et al., 2007, Yang et al., 2010, Knoll et al., 2011) 以及字典学习 (Zhan et al., 2015, Caballero et al., 2014, Ravishankar and Bresler, 2010) 等。DL-MRI 大致又可以分为以下两类: 1) 基于非迭代展开网络的重建方法, 该类方法从训练数据中学习一个从欠采样 k 空间数据 / 伪影图像至全采样 k 空间数据 / 无伪影图像的非线性映射函数。这种方法实现较为简单, 但可解释性较差, 没有将 MR 数据所特有的物理模型当成先验信息融入到方法中, 并且该类方法通常需要大量的全采样样本作为标签去优化网络参数。典型的方法有 U-Net (Ronneberger et al., 2015)、GANCS (Mardani et al., 2018) 以及 DeepComplex (Wang et al., 2020) 等; 2) 基于迭代展开网络的重建方法, 其将传统的 CS 算法迭代步骤中的图像变换域, 非线性函数替换为卷积神经网络 (Convolutional Neural Network, CNN), 其他自由参数替换为可学习参数, 最终通过神经网络的训练使得网络中的参数得以优化, 以此来完成 MR 图像的重建任务。这类方法从传统 CS 算法出发, 与深度学习进行了结合, 考虑到了 MR 物理模型, 因此图像重建效果也更加鲁棒, 其中典型方法有 ADMM-Net (Sun et al., 2016)、VN-Net (Hammernik et al., 2018)、ISTA-Net (Zhang and Ghanem, 2018) 以及 MoDL (Aggarwal et al., 2018) 等。

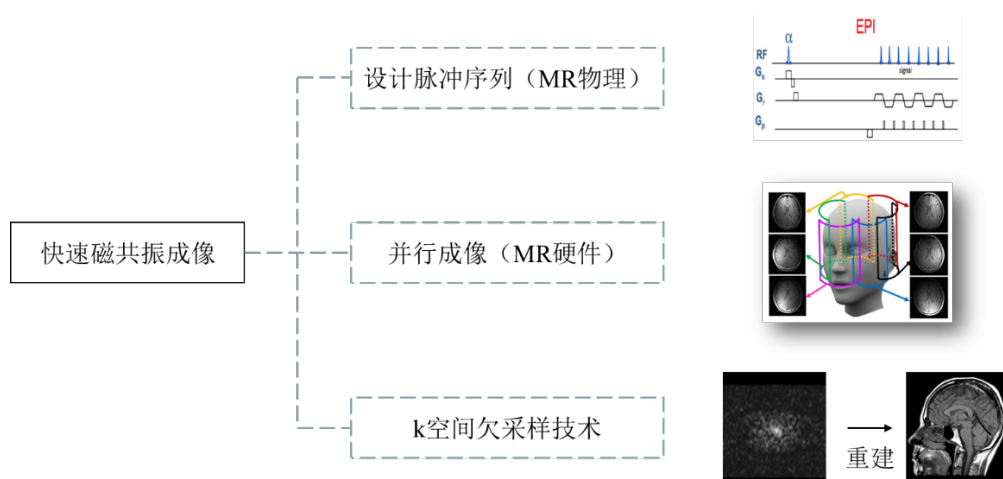


图 1.1 实现快速 MRI 的几种方法。

Figure 1.1 Several methods to realize fast MRI.

目前基于深度学习的重建方法在 MRI 领域被广泛研究，其中大多数为基于非迭代展开网络的重建方法，该类方法仅通过训练一个神经网络去拟合从欠采样数据到全采样数据的非线性映射函数，忽略了 MR 数据特有的成像方式，没有考虑到利用 MR 物理模型作为先验信息融入到方法中，因此，方法的重建性能以及泛化性有待提高。本文基于相关工作的启发，提出了一种新颖的传统迭代重建算法与深度神经网络进行结合的 MRI 重建方法。该方法从 MR 物理模型出发，用 CS 算法去求解非线性重建优化问题，然后与深度学习进行结合，同时具备迭代算法重建与深度学习重建两者的优点，即具有较强的稳定性和可解释性，能够减小对训练样本数量的依赖，同时可以实现网络端到端的训练，解决参数难调的问题。为了充分验证所提方法的有效性，我们将其应用至 MRI 重建任务中，并与已有的重建方法进行了对比，实验结果表明所提方法能够实现高质量的重建效果。

目前绝大多数基于深度学习的重建方法均需要全采样数据作为标签用于监督网络参数优化过程，然而由于物理或者生理上的约束，在一些成像任务中是难以获取到这些训练所需的全采样数据。为了解决深度学习重建方法对全采样 k 空间数据的依赖性问题，本文中我们根据 k 空间数据可分性以及欠采自相同切片理应重建出相同图像这一特性提出了一种基于 MR 物理模型的自监督重建方法，所提方法在网络模型的训练阶段只需要采集到的欠采样数据，能够有效解决上述全采样数据依赖性问题。为了充分验证该方法的有效性，我们将其与端到端重建方法、基于模型的重建方法以及已有的自监督重建方法进行了对比，定量分析与

定性分析结果均表明了所提方法能够在无任何全采样数据的情况下实现与基于监督学习的方法相当的 MR 图像重建质量。

1.2 国内外研究现状

MRI 是一种在临床研究与诊断中应用广泛的成像技术,其具有无创、无辐射,以及软组织对比度高的特点,可以实现多参数、多功能以及多角度成像,能够准确获取人体器官以及组织的生理功能和解剖结构。然而,磁共振数据的获取是一个相对缓慢的过程,其需要在 k 空间中顺序采集数据样本,采集速度也往往会受到成像对象的生理约束或者成像设备的硬件约束。而长时间的扫描过程不仅会增加病人的不适感,还会引入运动伪影,并且难以实现一些实时性要求较高的成像任务,例如动态(Bustin et al., 2020, Majumdar, 2013, Lingala et al., 2011, Jung et al., 2009, Tsao et al., 2003)、灌注(Zhang et al., 2017, Paulson et al., 2016, Law et al., 2004)和功能成像(Chaari et al., 2014, Gindi et al., 1993, Knudsen et al., 1999)等。自 MRI 开始应用于临床研究以来,如何加速其成像过程实现快速 MRI 一直以来都是该领域内的一个重要课题。

最初,研究人员根据傅里叶变换空间的共轭对称性(Feinberg et al., 1986)通过已采样到的数据推出其他未采样到的数据信息,该技术被称为部分傅里叶变换技术(Partial Fourier Transform, PFI)(McGibney et al., 1993)。通过该技术可以从采集到的一半的磁共振原始数据中重建出原始的高质量图像,然而在实际应用中为了实现稳定的相位矫正,采集到的 k 空间数据往往要多于一半,因此, PFI 技术所能实现的加速倍数实际上要小于 2 倍,这种加速程度显然是远远不足的。之后,基于多通道线圈的并行成像技术被研究人员所提出来了,该技术通过使用多个线圈采集 MR 原始信号,利用线圈之间的灵敏度编码信息来进行对未获取信息的恢复,提高了所能实现的信号采集加速倍数。为了利用多通道线圈灵敏度图中的冗余信息恢复出原始的高质量图像,研究人员提出了一系列的相关工作。1999 年 Pruessmann 等人通过利用线圈灵敏度曲线的先验知识在图像域通过解像素之间的混叠来重建出原始的 MR 图像,该方法被称之为 SENSE(Pruessmann et al., 1999),其实施简单,但由于线圈灵敏度信息在实际应用中难以精确的估计得到,从而其重建出来的图像可能会导致一定程度的伪影。2002 年 Griswold 等人提出了广义自校准部分并行成像 (GRAPPA)(Griswold et al., 2002),其不同于

SENSE 在图像域进行 MR 图像重建,该方法在 MR 原始信号的采集空间 (k 空间) 进行,利用相邻、已知的 k 空间频率信息估计出未知的 k 空间数据。该方法的具体实现为: 在自校准线 (Autocalibration Signals, ACS) 中估计出用于插值的卷积核参数,然后通过在整个 k 空间滑动卷积核,对卷积核大小范围内的已知 k 空间数据进行线性组合以获取目标点的频率信息。该方法不需要估计线圈灵敏度图,因此也避免了估计误差,在鲁棒性上也要优于 SENSE,然而,由于其要求 k 空间的拓扑结构是相同的,因此,该方法并不适用于非笛卡尔采样轨迹。2010 年 Lustig 等人提出了 SPIRiT 并行成像重建方法(Lustig and Pauly, 2010),其可以被视为 SENSE 和 GRAPPA 的结合,具有鲁棒性高、无需估计线圈灵敏度信息以及可应用于非笛卡尔采样轨迹的优点。SPIRiT 利用数据一致项以及校准一致项来保证重建图像的准确性,与 GRAPPA 一样,该方法也是通过利用相邻已知的 k 空间数据之间的相关性来估计未采样到的频率点信息,但是在重建上则是利用与 SENSE 一样的逆问题求解思路。而后,研究人员提出了很多用以并行成像的重建方法,其中大部分都是在上述几种典型的方法上进行改进的。比如使用特征向量图的并行成像方法 (ESPIRiT) (Uecker et al., 2014),该技术中运用了奇异值分解 (Singular Value Decomposition, SVD)。而 k -t SENSE(Xu et al., 2007)以及 k -t GRAPPA(Huang et al., 2005)则是利用了 MRI 序列中的时间相关性进行重建,进一步地加速了 MR 原始数据的采集过程。尽管并行成像技术的提出在一定程度上加速了 MRI 的成像过程,然而,其能实现的加速倍数始终有限,一般为 2-4 倍,这显然是不够。因此,人们通常会将并行成像与 CS 理论或者深度学习等方法进行结合使用,进一步提高 k 空间数据的欠采样率。

2006 年,研究人员首次提出了一种新的针对信号采样的技术,称之为 CS(Donoho, 2006)。在该理论下,信号在满足一定条件下,其欠采样率可以突破奈奎斯特采样定理的限制,极大地降低了采样数据量的需求。随后,2007 年, Lustig 等人首次将 CS 应用于 MRI 重建任务中以实现 MR 原始数据的加速采集 (Lustig et al., 2007),实现快速 MRI。在 CS-MRI 中,以下三个前提条件需要满足: 1) 待重建信号是稀疏的; 2) 欠采样矩阵满足 RIP 条件,即信号由于欠采样形成的伪影是不相干的; 3) 非线性重建方法,该重建方法需要满足采集到的磁共振原始数据的一致性约束以及信号的稀疏性约束。其中,关于稀疏性的最初相

关工作为使用 TV，离散余弦变换（Discrete Cosine Transform, DCT）以及 DWT 等固定基来稀疏表示 MR 图像，在较高的欠采样率下，该类方法由于只能表达某些简单的人为经验设置好的稀疏特征，导致有些特征不能被表达出来，从而造成重建图像上的部分细节信息丢失。字典学习将传统的固定稀疏基替换为超完备冗余字典(Ravishankar and Bresler, 2010)，通过从训练数据中学习自适应基，改善其特征表达能力，提升磁共振图像重建质量。

近些年来，深度学习在各种图像任务的应用中都取得了相当大的成功 (Goodfellow et al., 2014, Krizhevsky et al., 2012, Simonyan and Zisserman, 2014, He et al., 2016, Ren et al., 2015)，其深层次的卷积结构可以从训练数据中提取特征，以构建更为抽象的表示，从而可以替代人为经验性提取特征的方法。基于深度学习的方法实现简单，效果也比传统方法改善许多，成为目前的研究热点之一。Wang 等人第一次尝试将深度学习应用于 MRI 领域中(Wang et al., 2016)，通过直接训练一个深度神经网络模型来学习从欠采样图像到全采样图像之间的非线性映射函数，其成果于 2016 年发表于 ISBI 会议。在此之后，基于深度学习的磁共振重建方法不断地涌现出来，相关研究工作大致可以分为基于非迭代展开网络的重建方法以及基于迭代展开网络的重建方法。其中，基于非迭代展开网络的重建方法中典型的方法有基于编解码结构的 U-Net(Ronneberger et al., 2015)、k 空间插值的 RAKI(Akçakaya et al., 2019)、通过训练一个生成对抗网络用于从欠采样图像到全采样图像的生成 (GANCS) (Mardani et al., 2018)、以及从 k 空间和图像域交替变换进行重建的 KIKI-Net(Eo et al., 2018)等(Zhu et al., 2018, Yang et al., 2017)。大部分基于迭代展开网络的重建方法(Cheng et al., 2019)基本都是基于 CS 理论，将用于求解重建逆问题的迭代算法展开成神经网络的形式，并且其中所有的待定参数及非线性函数都可以通过端到端的网络训练学习得到。Yang 等人将交替方向乘子法 (Alternating Direction Multiplier Method, ADMM) 与神经网络结合(Sun et al., 2016)，通过网络自适应地从数据中学习正则化参数、迭代步长以及变换域等，实现准确地重建结果。此外，基于迭代展开网络的重建方法还有基于变分网络结构的 VN-Net(Hammernik et al., 2018)、基于迭代阈值收缩算法 (Iterative Shrinkage-Thresholding Algorithm, ISTA) 的 ISTA-Net(Zhang and Ghanem, 2018)、以及基于深度去噪先验的 MoDL(Aggarwal et al., 2018)等。目前基于深度学习的

重建方法绝大多数在网络的训练阶段都需要全采样数据作为标签来进行对网络参数的优化。最近, Yaman 等人(Yaman et al., 2020)提出了一种自监督的重建方法 (Self-supervised Learning via Data Undersampling, SSDU), 其将采集到的欠采样 k 空间数据划分为两个不相交的子集, 其中一个子集送入网络, 另一个子集用于定义损失函数。虽然能够实现不错的图像重建效果, 但该方法仍然存在不足之处, 例如: 当定义损失函数的数据点少时, 训练过程将会变得不稳定以及没有对未扫描频率点信息施加任何约束, 而这会增加重建结果的不确定性, 降低图像重建质量。

1.3 本文主要研究内容和创新点

本文针对快速 MRI 中的图像重建这一任务, 对基于 MR 物理模型和深度学习的快速成像方法进行了研究。本文涉及的研究工作有两项, 从网络训练所需全采样数据量这一方面而言, 第一项工作将 GAP 算法与深度学习结合进行重建可以较大地减少网络在训练阶段所需的全采样数据量, 而第二项工作自监督重建则可以使得网络模型在没有任何全采样数据的情况下也能够优化网络中的参数, 在缺乏全采样数据的情况下具有明显的研究意义。主要研究内容如下:

(1) CS 算法与深度学习结合的磁共振图像重建方法的研究

提出了一种将广义交替投影 (Generalized Alternating Projection, GAP) 算法与深度学习结合的磁共振图像重建方法, 该方法从 MR 物理模型出发, 将 GAP 算法迭代求解重建逆问题的迭代步骤中的图像稀疏变换域替换为深度学习中的卷积神经网络, 将迭代步长以及收缩阈值替换为可学习参数, 通过端到端的训练完成网络参数的优化, 从而实现高质量的磁共振图像重建。该方法隶属于深度学习中基于迭代展开网络的重建方法中的一种, 相较于传统的 CS 重建算法, 其具有重建速度快, 计算复杂度低以及无需手动设置参数的优点, 与深度学习中的基于非迭代展开网络的重建方法相比, 该方法具有数学可解释性强, 网络参数量较小以及所需训练样本量少的优点。为了验证所提方法的有效性, 我们将该方法与 U-Net 以及 MoDL 进行了对比, 实验结果表明所提方法能够实现高质量的重建效果, 可以恢复出更多的图像细节信息。

(2) 基于自监督学习的磁共振图像重建方法的研究

根据 k 空间数据可分性以及欠采自相同切片理应重建出相同图像这一特性提

出了一种基于 MR 物理模型的自监督图像重建框架,具体地,在网络模型优化阶段,通过随机选择一部分欠采样到的 MR 原始数据来构建两个子集,然后将其作为两个并行重建网络的输入来执行图像信息的恢复过程,通过对网络的输出在所有欠采样频率点处计算重建损失以增强网络恢复频率信息的能力。并且,为了保证网络在未采样到的频率点处信息恢复的准确性,有效约束网络重建解空间,提升图像重建质量,我们对两个并行重建网络的输出作出了一个差异性损失用于保证网络重建图像的一致性约束。通过这种方法,我们可以在缺乏全采样数据甚至没有任何全采样数据的情况下训练出用于磁共振图像重建的网络模型,可以有效解决传统深度学习重建方法在训练过程中对全采 k 空间数据的依赖性问题。理论上,所提框架可应用于目前任何一种基于深度学习的磁共振图像重建方法上以实现自监督重建。为了充分验证所提方法的有效性,我们将其应用于公开脑部 MR 数据集上实现图像重建,并与 U-Net、SSDU 以及相同网络模型下的监督重建方法进行了对比实验。实验结果表明,在高加速倍率下,所提方法能够实现与对应监督重建方法相当的磁共振图像重建质量。

1.4 论文内容安排

本文共分为以下五个章节进行阐述:

第 1 章 绪论。首先,介绍了本课题的研究背景以及研究意义;然后对 MRI 的国内外研究现状进行了一个简要的阐述与分析;最后简要介绍了本文所提的两个磁共振图像重建方法,总结了本文的主要研究内容以及创新点。

第 2 章 磁共振重建基础理论。首先对磁共振成像原理进行了一个简要介绍;然后介绍了压缩感知理论以及压缩感知磁共振成像的数学模型;最后介绍了目前几种基于深度学习的磁共振重建方法,分为基于非迭代展开网络的重建方法以及基于迭代展开网络的重建方法这两类进行阐述。

第 3 章 GAP 算法与深度学习结合的重建方法。介绍了 GAP 算法在求解重建逆问题中的迭代公式,并且将其与深度学习结合,然后将所提方法应用于 MRI 重建任务中,验证了其在脑部数据集上的性能。

第 4 章 基于自监督学习的 MRI 重建方法。介绍了所提自监督 MR 图像重建并行网络框架,其中包含对欠采样数据的随机选取过程、重建损失以及差异损失的定义,并以 ISTA-Net⁺为网络模型在公开 MR 数据集上进行了性能验证。

第 5 章 总结与展望。对本文的工作内容进行了总结，并且针对工作中尚且存在的不足进行了未来工作的展望。

第2章 磁共振重建基础理论

2.1 磁共振成像原理

1946 年 Bloch 和 Purcell 各自独立地发现了核磁共振现象，两人也因此获得了诺贝尔物理奖。Lauterbur 于 1972 年提出了一系列针对磁共振信号空间编码的方法，实现了从 MR 信号中重建出人体图像，从而使得 MRI 能够应用于临床诊断和治疗中，Lauterbur 也因在 MRI 领域取得的突破性成就获得了诺贝尔生理学或医学奖。此后，MRI 就一直是目前临床诊断和治疗中必不可少的一种成像技术。MRI 利用核磁共振原理，根据人体不同组织结构中的氢质子在能量释放过程中会呈现不同衰减速度这一特性，通过施加特定的梯度磁场以检测释放出来的 MR 信号，即可知道成像对象氢质子的位置以及种类，从而得到描述人体器官或者组织的结构图像。MRI 的成像过程大致可分为以下四个过程：磁化、激发与弛豫、空间编码以及重建(金永君 and 艾延宝, 2002 , Elmaoğlu and Çelik, 2011 , Liang and Lauterbur, 2000)，本文主要通过介绍 MRI 的不同成像过程来简要介绍其成像原理。

众所周知，一切物质都是由原子组成，而原子则是由原子核以及核外电子组成，其中，原子核由带正电的质子和不带电的中子组成。质子，中子以及电子都有自旋特征，因此称原子核也具有自旋特征，当质子和中子都为偶数时，自旋会相互抵消，即只有质子或者中子为奇数时，原子核才具备 MR 研究的物理条件。人体中的氢原子含量最多，原子核只有一个质子以及一个核外电子，结构比较简单，因此产生磁共振的能力最强，通常被用来作为共振对象产生 MR 信号。带正电的原子核进行自旋时，会产生和其他运动电荷一样的小磁场，可以用一个小磁矩来表示。正常情况下，这些小磁矩表现为杂乱无章的排列，因此整体不会呈现出磁性。当施加一个磁场强度较强的静磁场时，质子会产生磁化作用，磁矩方向开始沿静磁场方向排列，进而与静磁场方向保持一致。其朝向依据状态而定，其中，低能稳态的质子顺磁场方向排列，高能不稳态的质子逆磁场方向排列，两者数量上相差甚微，但即便如此，也足以产生顺磁场的磁化矢量。如图 2.1 所示，质子除了绕自身运动以外，同时也会沿着静磁场的磁力线为轴进行旋转，这种旋

转也被称之为拉莫进动，定义为：

$$\omega_0 = \gamma B_0 \quad \dots(2.1)$$

其中， γ 为旋磁比（单位：MHz/T，兆赫兹每特斯拉）， B_0 为主磁场强度（单位：T，特斯拉）， ω_0 为拉莫尔频率（单位：MHz，兆赫兹），对于氢质子，其旋磁比为 42.57MHz/T。




图 2.1 进动。(a) 进动圆锥示意图，(b) 置于主磁场的质子开始以 ω_0 逆时针旋转。

Figure 2.1 Precession. (a) Conical precession, (b) The protons placed in static field immediately start rotating with ω_0 at counterclockwise direction.

然而，此时磁化矢量在纵轴投影上的分量几乎不会发生变化，而通常我们想要测量某种信号，就必须产生一个动态的变化过程，其中，就需要利用到 RF 脉冲磁场。RF 是使质子群产生共振的关键磁场，质子在静磁场中被磁化，此时再施加一个 RF 脉冲磁场后，低能稳态的质子会吸收 RF 的能量变成高能不稳态，而当 RF 关闭之后，变成高能不稳态的质子会释放原本不属于它自己的能量，重新返回到原来的低能稳态状态。这个吸能放能的过程称之为激发与弛豫过程，在这个过程中会产生所需的 MR 信号。随着能量的释放，会产生自由感应衰减(Free Induction Decay, FID) 信号，横向磁化矢量的减小过程称为 T2 弛豫，纵向磁化矢量的增长过程则称为 T1 弛豫，人体中不同器官的不同组织具有不同的 T1 和 T2。在弛豫过程中产生的 MR 信号可通过接收线圈捕获，产生频率和质子进动频率相同的正弦波电流。

如前所述，我们已经简单了解了 MR 信号的产生过程，然而由于接收线圈捕获的信号是来自不同组织不同位置的加权，因此无法将其区分开，也无法形成有

用的 MR 图像。梯度磁场就可以帮助我们完成氢质子的空间编码,以获取其空间位置。在 MRI 扫描系统中,梯度磁场是通过梯度线圈产生的,可产生三个方向的梯度磁场,通过组合开关这三个梯度线圈,可完成层面选择,频率编码以及相位编码,最终可以确定捕获到的 MR 信号是来自哪个区域的,完成 MR 信号的空间编码。此时,在接收线圈接收到的信号实则是不同方向不同频率的二维平面波,这些波的叠加就形成了物理图像。如图 2.2 所示,所接收的 MR 原始信号编码于即 k 空间中,其中高频分量位于四周,代表着图像的细节信息,而低频分量位于中心位置,代表着图像的整体信息,当对采集到的 MR 原始数据进行二维傅里叶逆变换时,则可以得到我们肉眼可识的 MR 图像。

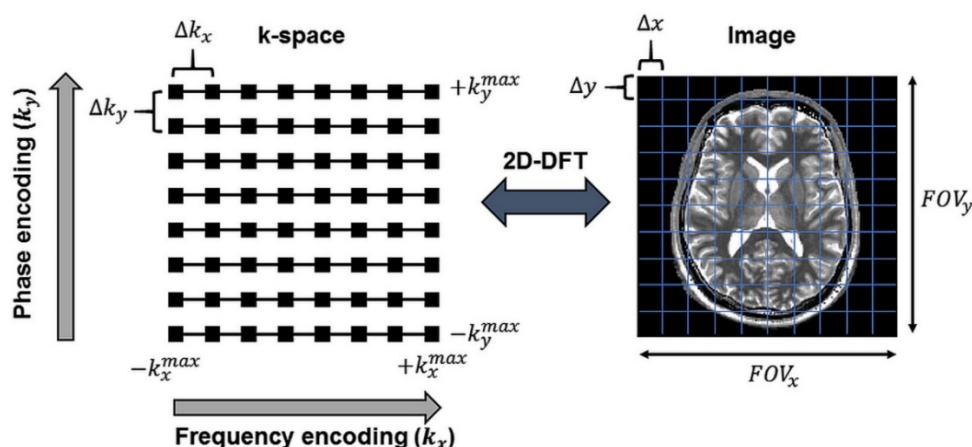


图 2.2 k 空间与图像域的对应关系(Hamilton et al., 2017)。

Figure 2.2 Correspondence between k -space and image domain(Hamilton et al., 2017).

2.2 压缩感知磁共振成像

在 CS 理论被提出来之前,信号采样通常遵循奈奎斯特采样定理,即对信号的采样频率应该大于等于信号中最高频率的两倍,否则采样之后的信号会出现频谱混叠的现象,造成不可逆的信息丢失,从而也就不能从欠采样信号之中完美地恢复出原始信号。对于 MRI 而言,这意味着我们需要对成像对象进行大量的数据采集,这不仅会造成 MR 原始数据扫描时间的增长,也会给成像硬件设备带来更高的要求, MRI 的发展也因此受到了制约。直到 2006 年,Donoho 和 Candes 等人(Donoho, 2006)首次提出一种新颖的针对信号采样的技术,称之为 CS 理论。在该理论下,对信号的采样倍数可以突破奈奎斯特采样定理的限制,极大地降低了对采样数据量的需求,减小了信息的冗余,加速了 MRI 的发展与应用。本章

节主要从 CS 理论以及 CS 在 MRI 中的应用这两方面简要介绍压缩感知磁共振成像 (CS-MRI)。

2.2.1 压缩感知理论

在 CS 理论下, 如果一个信号是稀疏的, 并且对其欠采样之后产生的伪影是不相干的, 那么就可以通过某种非线性重建方法对其进行完美恢复。从以上的陈述中, 我们可以总结出以下三个前提条件: 1) 信号是稀疏的或者其在某个变换域是稀疏的; 2) 欠采样矩阵满足 RIP 条件, 即信号由于欠采样形成的伪影是不相干的; 3) 用于重建出原始信号的非线性重建方法。以下从这 3 个条件对 CS 理论进行简要介绍。

信号稀疏性: 在 CS 理论中, 寻找到信号最稀疏的那个域是比较重要的, 因为此时信号可以由最少的特征系数的线性组合进行表示, 这就也意味着我们只需要存储少量的几个系数就可以完整地表示原始信号, 对数据的压缩与传输起到了非常重要的意义。当信号在某个域稀疏时, 可以通过以下的公式进行表示:

$$x = \Psi s \quad \dots (2.2)$$

其中, x 表示原始信号, Ψ 表示稀疏变换域, s 表示相应的稀疏系数。对原始信号 x 的稀疏要求则转为对 s 的稀疏约束, 即要求 s 的零值足够多, 在数学上可以通过 L_0 范数进行表示:

$$s: \|s\|_0 \leq K \quad \dots (2.3)$$

当系数 s 中有 K 个非零值时, 我们则称 s 为信号的 K 稀疏表示。

非相干采样: 在信号采样时, 我们期望能够通过欠采样到的少量数据就可以恢复出原始信号, 这就要求我们采集到的数据中就包含原始信号的大部分信息。而在 CS 理论中, 对信号的欠采样率通常要超出奈奎斯特采样定理的约束, 以 Φ 表示为观测矩阵, 则采集到的观测值可表示为 $y = \Phi \Psi s$, 此时得到的观测值 y 的维数会小于 s 的维数, 方程是欠定的, 一般而言从观测值中无法得到唯一确定的解。而 CS 理论告诉我们, 当观测矩阵 Φ 和稀疏矩阵 Ψ 不相干时, 即满足 RIP 约束条件时, 方程便会有精确解。

非线性重建: 信号欠采样操作可以加速数据的采集过程以及方便数据的传输, 而在此之后我们希望能够获取原始信号更多的信息, 因此通常需要从欠采样信号

中完成原始信号的重建。在 CS 理论下，当观测矩阵满足 RIP 条件时，可以将该重建问题转化为一个非线性优化问题，从而进行迭代求解，由于 L_0 范数是离散的，比较难以优化，而在一定条件下， L_0 范数可等价于 L_1 范数，所以求解的最优化问题可表示为：

$$\min_s \|s\|_1 \quad \text{s.t. } y = \Phi \Psi s \quad \dots (2.4)$$

当解上式最优化问题得到稀疏系数 s 的最优估计为 s' ，则对原始信号的最优估计为 $x' = \Psi s'$ 。

2.2.2 压缩感知磁共振成像模型

如前所述，CS 理论的提出使得对信号的采样倍数可以突破奈奎斯特采样定理的限制，这极大程度上减小了对采样数据量的需求。2007 年，Lustig 等人 (Lustig et al., 2007) 首次将 CS 理论应用于 MRI 领域中以减小 MR 原始信号的数据采集量，加速其成像过程，使得 MRI 能够更为广泛地应用于临床诊断和治疗当中。MRI 领域中之所以能够引入 CS 理论，明显缩短扫描时间，与其特性紧密相关。首先，MR 图像通常是稀疏的，即满足了 CS 理论的稀疏性条件；其次，利用随机或者伪随机的欠采样轨迹对 MR 原始数据进行采样可以以较高概率满足 CS 理论中的非相干性条件；最后，可以通过非线性重建方法从欠采样图像中恢复出高质量的 MR 图像。

在 CS-MRI 模型中，MR 图像可以在某个变换域下是具有稀疏性的，对 MR 原始数据的欠采样被视之为非相干采样，通过求解非线性优化问题以满足对欠采样 k 空间数据的数据一致性约束以及原始 MR 图像的稀疏性，其中，两者通过正则化系数进行平衡。用以约束图像稀疏性的方法之一是利用 L_0 范数计算稀疏矩阵中的非零个数，其值是离散的，所以对其进行优化是比较困难的。而在一定条件下，优化 L_1 范数可以达到和优化 L_0 范数等价的效果，因此，我们通常会将 L_0 范数替换为 L_1 范数。总之，CS-MRI 的非线性重建优化问题可以表示为：

$$\operatorname{argmin}_x \frac{1}{2} \|Ax - y\|_2^2 + \lambda \|\Phi x\|_1 \quad \dots (2.5)$$

其中， $A = PFS$ 为编码矩阵， P 表示为欠采样矩阵， F 表示为傅里叶变换矩阵， S 表示为并行成像中的灵敏度矩阵； x 表示为原始 MR 图像， y 表示为欠采样 k 空

间数据, Φ 表示为图像稀疏变换域, λ 表示为正则化系数。在该非线性优化问题中, 第一项意味着我们期望得到的重建图像经过相应的编码之后, 在欠采样频率点处的信息与采集到的 k 空间数据保持一致, 该项因此也被称之为数据一致性项; 第二项则是图像稀疏性约束, 其要求图像在某个变换域中足够的稀疏, 一般而言, 除了施加稀疏性约束, 还可以其他约束, 例如, 在动态成像中通常会施加低秩约束, 所以我们通常称数据一致性项之外的项为正则化项, 而数据一致性项与正则化项之间的平衡则可以通过正则化系数进行保持。对于上述非线性优化问题, 可以通过多种凸优化技术进行求解, 比如 ADMM 以及共轭梯度 (Conjugate Gradient, CG) 法等。而对于上式的稀疏算子, 则可以使用 FT、TV 或者小波变换 (Wavelet Transform, WT) 等, 亦或者可以从数据中进行自适应的学习。

2.3 基于深度学习的磁共振重建方法

将 CS 理论引入 MRI 中较大地加速了 MR 原始数据的采集过程, 使得 MRI 在临床诊断和治疗中得到了更广泛的应用。然而, 通过这种方法重建出来的 MR 图像的质量在相当程度依赖于稀疏变换域的选择, 当选择的变换域过于简单时, 则无法表达出较为复杂的特征, 这会导致重建图像与原始图像相比缺乏一些必要的图像细节, 从而看起来不自然。并且, 传统的 CS 重建方法通常需要进行迭代求解, 而迭代求解的过程较慢, 计算复杂度较高, 因此需要较长的计算时间, 除此之外, 传统 CS 重建方法一般需要人为经验性的设置一些参数, 比如迭代步长以及收缩阈值等, 不合适的参数选择会影响最终的图像重建质量, 使得 MR 图像残留部分混叠伪影或者导致过度平滑的情况。

近些年来, 一种称之为深度学习的技术在图像分类、图像分割、图像去噪去模糊以及其他计算机视觉任务中应用广泛, 该方法通过在离线地对训练数据的拟合过程中不断地优化神经网络参数, 然后将相应的网络模型以及学习到的固定网络参数用作其他数据的测试, 其实现简单且性能优越, 不断刷新各视觉任务领域的榜单。在 MRI 重建任务中, 也有不少基于深度学习的重建方法被提出来用于改善 MR 图像重建质量, 相关的研究工作大致可分为基于非迭代展开网络的重建方法以及基于迭代展开网络的重建方法。以下, 本章节主要分类别简要介绍其中几种较为典型的 MRI 重建方法。

2.3.1 基于非迭代展开网络的重建方法

基于非迭代展开网络的重建方法通常是直接从训练数据中学习一个从欠采样 k 空间数据 / 伪影图像至全采样 k 空间数据 / 无伪影图像的非线性映射函数。该类方法所能实现的 MR 图像重建质量与网络结构的设计具有紧密的联系，不同的网络结构对图像特征的提取与利用是不相同的，一般而言，网络模型中通常包含卷积层、非线性函数激活层以及池化层等操作。典型的基于非迭代展开网络的重建方法有 U-Net、ResNet(He et al., 2016)、KIKI-Net 以及 GANCS 等，本章节中，主要对 U-Net 以及 KIKI-Net 这两种方法进行一个简要介绍。

U-Net: 2015 年, Ronneberger 等人在国际会议 MICCAI 上首次提出了一种新型的网络模型用于医学图像分割, 该网络模型由几个连续的下采样操作之后接几个连续的上采样操作, 特征图的尺寸从大变小再从小变大从而使得输出图像的尺寸与输入图像保持一致, 因此被称之为 U-Net。下采样操作浓缩特征, 增强语义信息, 上采样操作恢复图像像素点信息, 并且通过跳跃连接的方式将低层特征与高层特征结合, 增加了特征的信息丰富度, 因此实现了在当时较好的分割效果。目前, U-Net 以及其后续的变体已成功应用于除图像分割的其他图像任务当中, 比如图像去噪以及 MRI 重建(Zbontar et al., 2018)等。其用于 MRI 重建中的网络结构如图所示:




图 2.3 U-Net 应用于 MRI 重建中的网络结构图(Zbontar et al., 2018)。

Figure 2.3 MR reconstruction network based on U-Net architecture(Zbontar et al., 2018).

首先图像经过两次 3×3 卷积组合操作初步提取特征, 然后通过最大池化层浓缩特征信息, 此时特征图的空间尺寸会减半, U-Net 中这样的操作可以重复多次, 具体重复次数和图像任务以及输入图像尺寸有关系, 在上述单通道 MR 图像

重建任务中重复了 4 次。在连续的二次卷积再池化的操作过程中，特征图的空间尺寸不断减小，提取到的语义信息也越来越高层。在此之后，则采用上采样加二次卷积的方式不断提升特征图的空间尺寸，恢复出图像像素信息，其中，上采样操作采用的是双线性插值法。这种操作的重复次数与下采样次数保持一致，从而可以使得输出图像的空间尺寸与输入图像保持一致。U-Net 在下采样卷积网络与上采样卷积网络中间还增添了一条跳跃连接，可以使得低层的特征和对应的高层特征进行结合，较大地增加了特征的信息丰富度，提高了特征的利用率，因此效果上也能够得到改善。整个网络的训练是以端到端的方式进行的，损失函数则可以在输入图像与输出图像之间计算一个均方误差（Mean Square Error, MSE），然后通过最小化在训练数据集上的损失函数完成网络参数的优化。

KIKI-Net: 在此之前，相关 MRI 重建的工作都只是在图像域或者 k 空间进行丢失信息的恢复，而没有考虑到同时在这两个域上进行重建。2018 年，Eo 等人在 MRI 领域期刊 MRM 上提出了一种跨域 MR 图像重建方法，该方法由三个部分组成：1) 在 k 空间进行恢复的 CNN (KCNN)；2) 在图像域进行恢复的 CNN (ICNN)；3) 数据一致性操作 (IDC)。这三部分组合成一个整体然后迭代重建进行多次最终输出网络的重建图像。其中一个迭代重建数据流图如图所示：

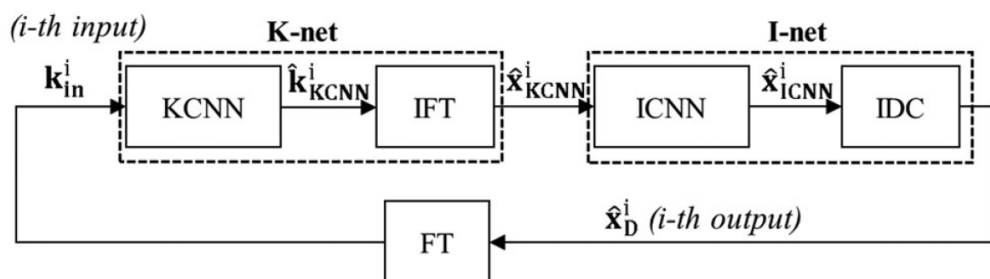


图 2.4 KIKI-Net 数据流和中间操作框图(Eo et al., 2018)。

Figure 2.4 Block diagram for data flow and intermediate operations of KIKI-Net(Eo et al., 2018).

在网络的第一个迭代重建步骤中，将欠采样 k 空间数据作为 KCNN 的输入，得到的输出即为在 k 空间进行了信息恢复的 k 空间数据，然后将其进行逆傅里叶变换操作 (IFT) 变换至图像域，以此结果作为 ICNN 的输入在图像域进行恢复，之后，对 ICNN 的输出做一次数据一致性操作 (IDC)，即保证恢复结果在原始欠采 k 空间频率点处的信息保持不变，而对其他频率点处的信息则保留，因为欠采样到的频率点信息是最具有真实性的，该操作在数学形式上可表示为：

$$\hat{k}_D(k_x, k_y) = \begin{cases} \frac{\hat{k}_{ICNN}(k_x, k_y) + \lambda k_u(k_x, k_y)}{1 + \lambda} & \text{if } U(k_x, k_y) = 1 \\ \hat{k}_{ICNN}(k_x, k_y) & \text{if } U(k_x, k_y) = 0 \end{cases} \quad \dots (2.6)$$

其中, $\hat{k}_{ICNN}(k_x, k_y)$ 表示为 ICNN 输出的二维傅里叶变换结果, $U(k_x, k_y)$ 表示欠采样 k 空间频率点, 上式中 $\lambda \rightarrow \infty$ 。之后, 对 IDC 的输出进行傅里叶变换用以作为下一个迭代重建网络模块 KCNN 的输入, 最后一个重建模块的输出则作为 KIKI-Net 的最终重建结果, 以重建图像与原始真实图像之间的误差进行反向传播优化每个迭代重建模块中 KCNN 和 ICNN 的参数。其中, KCNN 和 ICNN 的结构中均包含特征提取块, 推理块以及重建块, 特征提取块将实部与虚部分离开并分别提取相应的特征信息, 然后将两者进行拼接 (Concat) 之后送入推理层进行信息的推理恢复, 之后在重建块将实部与虚部进行结合作为输出。

2.3.2 基于迭代展开网络的重建方法

基于迭代展开网络的重建方法是将传统 CS 算法与深度学习进行结合的一类 MRI 重建方法, 其通常将传统的 CS 算法迭代步骤中的图像变换域与非线性函数替换为 CNN, 迭代步长、收缩阈值以及其他自由参数替换为神经网络中的可学习参数, 最终通过网络训练使得神经网络中的参数得以优化, 以此来完成 MR 图像的重建任务, 根据不同约束项或者不同变换形式可通过不同的优化算法进行重建逆问题的求解。典型的基于迭代展开网络的重建方法有 ADMM-Net、VN-Net、MoDL 以及 ISTA-Net 等, 本章节主要对 ADMM-Net 以及 MoDL 这两种方法进行简要介绍以说明传统 CS 算法是如何与深度学习进行结合应用于 MRI 重建任务中的。本文后续提出的 GAP-Net 也属于这一类方法, 将在第三章进行详细阐述。

ADMM-Net: 在 CS-MRI 重建模型中, 可利用 ADMM 算法迭代求解非线性优化问题, ADMM-Net 即是在 ADMM 算法的基础上与深度学习进行结合的 MRI 重建方法。该方法与基于非迭代展开网络的重建方法类似, 也存在着网络模型的训练以及测试这两个阶段, 训练阶段中利用反向梯度传播算法对整个模型中的网络参数进行端到端的优化, 以使得更好地拟合训练数据集中的样本, 使网络的输出图像与相应全采样标签图像之间的差异最小, 而在测试时则是利用学习到的优化参数来完成 MRI 图像重建任务。ADMM-Net 的数据流图如下图所示:




图 2.5 ADMM-Net 的数据流图(Sun et al., 2016)。

Figure 2.5 The data flow graph of ADMM-Net(Sun et al., 2016).

该网络结构与 ADMM 算法一样也存在着迭代重建的过程，因此显示成多个 stage，每个 stage 由四个模块构成：1) 重建层 $X^{(n)}$ ，此层用于更新重建图像；2) 卷积层 $C^{(n)}$ ，通过卷积操作将图像变换至变换域中；3) 非线性变换层 $Z^{(n)}$ ，执行非线性操作用于更新 ADMM 算法中引入的辅助变量；4) 乘子更新层 $M^{(n)}$ ，该层针对增广拉格朗日函数中引入的拉格朗日乘子项进行更新。该方法以欠采样图像作为网络的输入，最后一个 stage 的输出额外更新一次图像作为整个网络最终的重建结果，计算网络输出结果与全采样图像之间的标准均方误差 (Normalized Mean Square Error, NMSE)，以此作为损失函数进行误差反向梯度传播以使得网络中的参数得以优化。

MoDL: 在 CS-MRI 重建模型中，对于正则项的设计通常是人为经验性的，比如常用的稀疏性以及动态成像中的低秩性。而在该方法中，作者利用 CNN 去噪器作为 CS-MRI 模型中的正则化项，提出了一种基于模型的图像重建框架。由于 CNN 的强大性以及灵活性，因此该框架方法为求解任意结构逆问题的深层体系结构提供了一种系统的方法，并且，相较于传统基于深度学习的重建方法，该方法具有参数量少，可解释性较强的优点。MoDL 从求解以下非线性优化问题开始：

$$x_{rec} = \underset{x}{\operatorname{argmin}} \|Ax - b\|_2^2 + \lambda \|x - D_w(x)\|^2 \quad \dots (2.7)$$

其中， A 为编码矩阵， x 为原始图像， x_{rec} 为网络重建结果， b 为欠采 k 空间数据， $D_w(x)$ 表示为 CNN 去噪器， λ 表示为正则化系数。上式第一项称之为数据一致性项，期望网络重建出来的结果在采样频率点处的值与原始欠采样 k 空间数据保持一致，第二项则称之为正则化项，期望其达到最小值，即重建出来的 MR 图像是

干净无伪影的。通过求解，其迭代公式可表示为：

$$z_n = D_w(x_n) \quad \dots(2.8)$$

$$x_{n+1} = (A^H A + \lambda I)^{-1} (A^H b + \lambda z_n) \quad \dots(2.9)$$

其中 z_n 就表示为对输入 x_n 的去噪结果图像。关于 x_n 的更新，作者使用了共轭梯度这种数值优化方法，相较于近端梯度法，该方法具有更快的收敛性，以及不受迭代次数限制的优点。其网络结构框图如图所示，(a)中 N_w 表示通过 CNN 学习到的图像噪声或者伪影，在 CNN 的输入与输出中添加一条残差连接以表示去噪器 D_w ，每个迭代过程中的去噪器 D_w 参数共享权重。整个网络模型的输入为欠采样图像，通过 CNN 去噪器得到去噪图像之后以共轭梯度下降法更新重建图像，然后以更新之后的图像作为下一个迭代步骤中的输入，依此迭代进行重建，在最后一个迭代过程中输出网络最终的重建结果。

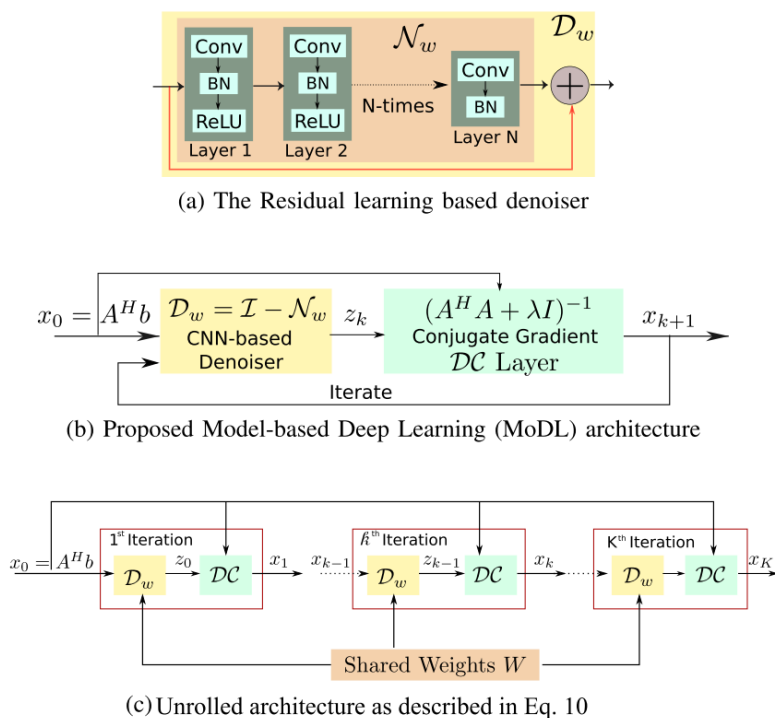


图 2.6 MoDL 网络结构框图(Aggarwal et al., 2018)。

Figure 2.6 The network structure block diagram of MoDL(Aggarwal et al., 2018).

2.4 本章小结

本章主要针对 MRI 重建的基础理论知识进行了一个介绍。首先，回顾了 MRI

成像原理,说明了 MR 信号的产生过程;之后介绍了 CS 理论以及 CS-MRI 模型,说明了在该模型下的 MRI 重建问题可视为求解一个非线性优化问题,此问题可通过不同的优化算法进行迭代求解;最后,介绍了基于深度学习的 MRI 重建方法,分为基于非迭代展开网络的重建方法以及基于迭代展开网络的重建方法这两类,前者是直接从训练数据中学习一个从欠采样 k 空间数据 / 伪影图像至全采样 k 空间数据 / 无伪影图像的非线性映射函数,主要介绍了 U-Net 和 KIKI-Net 这两种基于非迭代展开网络的重建方法;后者则是将传统 CS 算法与深度学习进行结合,将 CS 算法迭代步骤中的非线性函数以及自由参数替换为深度学习中的 CNN 和可学习参数,以此实现 MRI 重建,主要介绍了 ADMM-Net 和 MoDL 这两种基于迭代展开网络的重建方法。

第3章 GAP 算法与深度学习结合的重建方法

3.1 引言

将 CS 理论应用于 MRI 中可以使得对 MR 原始数据的欠采样倍数突破奈奎斯特采样定理的限制,极大地降低了对采样数据量的需求,加速了 MRI 的扫描过程,使得 MRI 能够更为广泛地应用于各种临床诊断和治疗中。然而,以较高的欠采样率对 MR 原始数据进行采样会导致一个病态欠定的线性重建问题。在 CS-MRI 模型中,通常会在适当的变换域内通过稀疏正则化的方法,融合图像固有低维的先验信息,以此实现对该问题的适定,其中,常用的变换域有 WT,有限差分,TV 以及 DCT 等。通过施加正则化项可以对解空间进行有效的限制,然而这也会使得 MRI 重建变成一个非线性优化问题。传统的 CS 重建算法便是以一种迭代优化的方式来求解该非线性问题,比如 ADMM 算法以及 ISTA 算法等,然而,迭代过程较长,且迭代求解过程的计算量通常会比较大,因此,这种方法通常是时间、资源密集型的方法,在需要实时性的 MRI 成像任务中难以应用。除此之外,由于迭代步骤中通常会含有迭代步长,收缩阈值等其他自由参数,因此需要事先进行人为设置,而最佳参数的设置通常是比较困难的。

近些年来,基于深度学习的方法在 MRI 重建任务中应用广泛。起初,相关重建工作通常是直接训练一个深度神经网络去拟合从欠采样 k 空间数据 / 伪影图像至全采样 k 空间数据 / 去伪影图像的非线性映射函数,典型的方法有 U-Net, KIKI-Net 等。与传统 CS 迭代重建方法相比,这类方法能够在实现高质量图像重建的同时缩短重建时间。然而,该类方法忽略了 MR 数据特有的成像方式,没有考虑到利用 MR 物理模型作为先验信息融入到方法中,方法的重建性能以及泛化性有待提高。由于其“黑盒子”的网络训练过程,此类方法缺乏一定的可解释性,除此之外,网络模型的训练阶段通常需要大量的全采样 k 空间数据作为标签去优化网络参数,而这在一些实际的成像任务中是难以获取的。随后,研究人员将传统 CS 重建算法与深度学习进行结合,提出了一种新的重建方法,由于其具有迭代重建的过程,因此也被称为基于迭代展开网络的重建方法,典型的方法有 ADMM-Net、ISTA-Net 以及 MoDL 等。该类方法根据不同约束项或者不同变换

形式可通过不同的优化算法进行重建逆问题的求解,然后通过从训练数据中学习重建网络中的约束项和参数,因此,这种方法可以在训练数据较小的情况下取得良好的性能。

本章节中,我们提出了一种新颖的将广义交替投影(GAP)算法(Liao et al., 2014)与深度学习结合的重建方法,取名为 GAP-Net,该方法隶属于基于迭代展开网络的重建方法,具有可解释性较强,不用手动经验性设置参数,所需训练样本少以及推理速度快的优点。该方法将 GAP 算法求解重建逆问题的迭代步骤中的非线性函数、迭代步长以及其他自由参数替换为深度神经网络以及可学习参数,通过端到端的训练完成网络模型参数的优化,实现高质量的 MR 图像重建。

3.2 方法论

3.2.1 GAP 算法求解重建逆问题

在 CS-MRI 模型下, MRI 重建问题可表示为以下一般形式的非线性优化问题的求解:

$$\min_x \frac{1}{2} \|Ax - y\|_2^2 + \lambda R(x) \quad \dots (3.1)$$

其中, A 表示为编码矩阵, x 表示为原始图像, y 表示为欠采样 k 空间数据, λ 表示为正则化系数, $R(x)$ 表示为对原始图像 x 施加的正则化项,在 ISTA-Net 中该正则化项特定为 L_1 范数,旨在约束原始图像 x 在某个变换域中的稀疏性,而在 MoDL 中该项则特定为基于 CNN 实现的深度去噪器。

在 GAP 算法下,公式 3.1 中的正则化项也被特定为对原始图像在某个变换域下的稀疏性约束,即 $R(x) = \|Dx\|_1$, 其中, D 表示原始图像对应的稀疏变换域,因此,公式 3.1 可以重新表示为:

$$\min_{x, C} \|Dx\|_1 \leq C \quad s.t. Ax = y \quad \dots (3.2)$$

其中, C 表示为基于正则化项 $\|Dx\|_1$ 的 L_1 超空间球的半径。将其作为一系列交替投影问题进行求解,并引入辅助变量 θ , 则可以将公式 3.2 中的优化问题表述为如下形式:

$$(x^{(t)}, \theta^{(t)}) = \operatorname{argmin}_{x, \theta} \frac{1}{2} \|x - \theta\|_2^2 \quad s.t. \|D\theta\|_1 \leq C^{(t)} \text{ and } Ax = y \quad \dots (3.3)$$

其中, t 表示为迭代次数。用增广拉格朗日函数表示, 则公式 3.3 可等价地表示为以下形式的非线性优化问题:

$$(x^{(t)}, \theta^{(t)}) = \underset{x, \theta}{\operatorname{argmin}} \frac{1}{2} \|x - \theta\|_2^2 + \lambda \|D\theta\|_1 \quad s.t. Ax = y \quad \dots (3.4)$$

其中, λ 表示为正则化系数。从公式 3.4 中我们不难看出, 该优化问题的目的是求出原变量 x 和辅助变量 θ 的解, 使两者在 L_2 范数意义下尽可能地相近, 除此之外, 辅助变量 θ 在某个变换域下具有足够的稀疏, 最后, 原变量 x 还应该满足数据一致性约束。

在 GAP 算法下, 公式 3.4 中该优化问题的求解可在原变量 x 以及辅助变量 θ 之间交替优化下进行。给定辅助变量 θ , 原变量 x 的更新可看作为 θ 在线性流形空间上的欧式投影, 表示为如下形式:

$$x^{(t)} = \theta^{(t-1)} + A^H(AA^H)^{-1}(y - A\theta^{(t-1)}) \quad \dots (3.5)$$

假设其中的操作 AA^H 是可逆的, 而这一点在大多数 CS 理论应用场景下通常是容易满足的。为了加速原变量 x 的更新过程, 可以使上述线性流形进行自适应的调整, 因此公式 3.5 可以调整为以下形式:

$$\begin{aligned} x^{(t)} &= \theta^{(t-1)} + A^H(AA^H)^{-1}(y^{(t-1)} - A\theta^{(t-1)}) \\ y^{(t)} &= y^{(t-1)} + (y - A\theta^{(t-1)}), \forall t \geq 1 \end{aligned} \quad \dots (3.6)$$

而给定原变量 x , 辅助变量 θ 的更新则可以视之为一个去噪的问题, 可通过迭代收缩算法 (Iterative clipping algorithm) 进行求解 (Yuan et al., 2020, Beck and Teboulle, 2009, Zhu et al., 2010, Yuan, 2016), 其更新公式可以表示为如下形式:

$$\theta^{(t)} = x^{(t)} - D^H z^{(t)} \quad \dots (3.7)$$

$$z^{(t+1)} = \operatorname{clip}\left(z^{(t)} + \frac{1}{\alpha} D\theta^{(t)}, \frac{\beta}{2}\right) \quad \dots (3.8)$$

其中, α 为迭代步长, β 为收缩阈值, $\operatorname{clip}(\cdot)$ 函数表示为:

$$\operatorname{clip}(b, T) := \begin{cases} b, & \text{if } |b| \leq T \\ T \operatorname{sign}(b), & \text{otherwise} \end{cases} \quad \dots (3.9)$$

至此，得出了 GAP 算法在求解 MRI 重建逆问题时的全部迭代公式，整个重建算法的迭代步骤为：1) 根据 $\theta^{(t)}$ 利用公式 3.6 得到 $x^{(t+1)}$ ；2) 根据 $\theta^{(t)}$ 和 $z^{(t)}$ 利用公式 3.8 得到 $z^{(t+1)}$ ；3) 根据 $x^{(t+1)}$ 和 $z^{(t+1)}$ 利用公式 3.7 得到 $\theta^{(t+1)}$ ；4) 根据上述步骤进行多次迭代更新得到最终的重建图像。其中，GAP 算法迭代公式中的初始值设置为 $\theta_0 = A^H y$, $y_0 = 0$, $z_0 = 0$ ，图像稀疏变换域 D ，迭代步长 α 以及收缩阈值 β 则需要事先假设或者经验性的设置，通常情况下，可用 WT, DCT 或者 TV 作为一种图像稀疏约束。

3.2.2 GAP-Net 网络框架

GAP 算法用于求解 MRI 非线性优化问题进行图像重建，其具有较强的稳定性以及数学可解释性，但通常而言，其迭代过程相对较长，迭代步骤中的计算量较大，并且图像稀疏变换域 D ，迭代步长 α 以及收缩阈值 β 通常需要人为经验性的设置，如何设置这些因素会直接影响 GAP 算法最终的图像重建质量。而深度学习中的 CNN 具有较强的特征表达能力，能够从对训练数据的拟合过程中学习到与数据分布相匹配的最优参数，并且其测试阶段通常利用 GPU 进行离线计算，推理速度相对较快。基于此，本章节提出了一种将 GAP 算法与深度学习进行结合的 MRI 重建方法，取名为 GAP-Net。与 GAP 算法迭代求解 MRI 重建逆问题类似，本章节所提方法网络模型中也还有多个迭代重建过程，GAP-Net 整体网络框图可表示为图 3.1。首先，我们将欠采样图像作为 θ_t 的初始值，即 $\theta_0 = A^H y$ ，根据 θ_0 利用公式 3.6 可计算得到 x_1 ，然后根据 θ_0 以及初始化为零值的 z_0 利用公式 3.8 的网络化结构得到 z_1 ，最后根据 x_1 和 z_1 利用公式 3.7 的网络化结构得到更新的 θ_1 ，此为本方法的第一个迭代重建步骤。将前一个迭代过程中更新得到的辅助变量 θ 作为当前迭代过程中的输入开启新一轮的重建，依次进行在最后的迭代重建步骤中便可得到最终的重建图像 θ_{k+1} 。




图 3.1 GAP-Net 整体网络框图。

Figure 3.1 The overall network diagram of the GAP-Net.

其中,第 t 个迭代重建步骤中的具体网络模型结构可表示为图 3.2。我们在本章节所提方法中将公式 3.7 以及公式 3.8 中的非线性图像变换函数替换为了深度学习中的 CNN,其为卷积,非线性激活函数以及卷积的组合操作,而公式 3.8 中的迭代步长 α 以及收缩阈值 β 则替换为可学习参数,可通过端到端的网络训练进行优化。在第 t 个迭代重建步骤中, θ_t 通过单层的卷积层进行输入特征的提取,此时的通道数由 1 变成 N_f ,本章节实验中, $N_f = 32$ 。之后通过用 CNN 进行替换的图像稀疏变换域 D ,在网络的输入与输出之间我们增加了一条跳跃连接,用以避免由于网络深度过长而可能导致的梯度消失以及梯度爆炸等问题,使得计算出来的误差能够更好地进行反向传播,网络参数能够得以更好地优化。之后通过 $\text{clip}(\cdot)$ 截断函数得到更新的 z_{t+1} ,以此作为网络化结构的 D^H 的输入进行后续的操作,最后,通过一个单层卷积层将特征图通道数从 32 变为 1,得到更新后的辅助变量 θ_{t+1} 。整个过程中,图像尺寸始终保持不变,各个变量的通道数也始终保持一致。

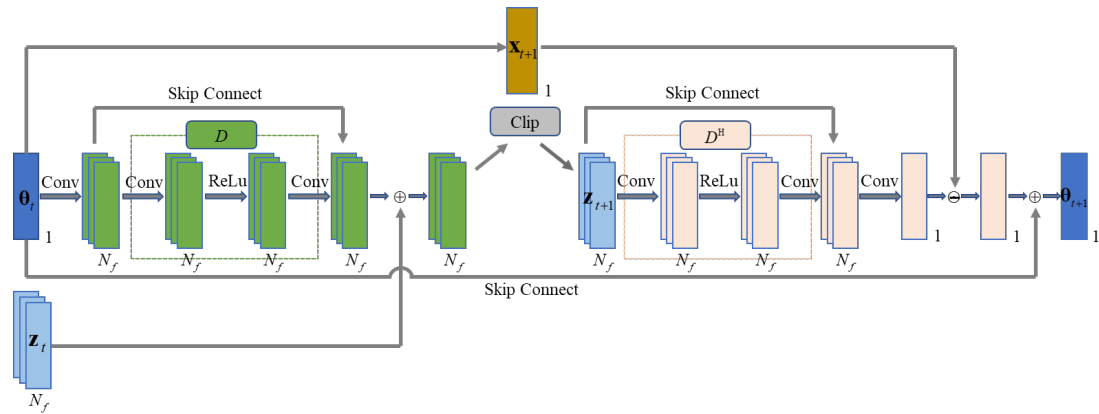


图 3.2 GAP-Net 第 t 个迭代重建网络结构图。

Figure 3.2 The network architecture of the k -th phase of the GAP-Net.

3.2.3 实现细节

从公式 3.4 中不难看出,当求解该非线性优化问题时,引入的辅助变量 θ 与原变量 x 会趋于一致,因此,我们可以视 GAP-Net 的第 k 个迭代步骤的输出 θ_{k+1} 为整个网络模型的输出图像,可利用该输出图像与原始图像 x 计算网络的重建损失,因此,本章节所提方法 GAP-Net 在网络模型训练阶段所使用的损失函数可表示为:

$$\mathcal{L}(\Theta) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(\theta_{k+1}^i, x^i) \quad \dots (3.10)$$

其中, N 表示为训练集样本数, θ_{k+1}^i 表示为第 i 个训练样本在网络模型中第 k 个迭代重建步骤的输出, 也即为整个网络模型的输出图像, 在本实验中, 我们将迭代次数 k 设置为 9, x^i 表示为第 i 个训练样本对应的全采样图像, $\mathcal{L}(\cdot)$ 表示为某种相似性度量指标, 本实验中, 所利用到的相似性指标为 MSE, 该损失函数是在图像中逐像素进行计算的。

本章节所提重建方法基于深度学习框架 PyTorch 实现。GAP-Net 网络模型的参数通过 Xavier(Glorot and Bengio, 2010)进行初始化, 其中的 gain 设置为 1。我们将初始的学习率设置为常用的 0.0001, 之后当损失函数在验证集趋于稳定的时候, 我们将学习率以一个固定的比例进行调正, 本实验中该比例为 0.3。最小批次设置为 4, 网络训练阶段使用 Adam 优化准则(Kingma and Ba, 2014)去优化网络模型中的参数。本章节中所有实验都是在装配有两张英伟达 RTX 2080 Ti (显存为 11 GB) 的 64 位 Ubuntu 18.04 LTS 操作系统上进行的。

3.3 实验结果与分析

数据集: 本章节实验中所使用的数据集为内部非公开数据集, 已通过伦理委员会审核并且取得了患者的知情同意。该数据集为三维多通道 T2 对比度脑部数据集, 通道数为 12, 共有 99 个病例, 我们将其按训练集: 验证集: 测试集约为 3: 1: 1 的比例进行数据的划分, 因此, 训练集含有 61 个病例, 而验证集以及测试集均含有 19 个病例。我们使用 ESPIRiT 方法从数据中估计得到灵敏度图, 之后通过通道合并操作将多通道数据合并成单通道图像进行实验, 对于每个合并之后的全采样图像, 我们均对其进行归一化操作, 即将图像的最大幅值限制在 1 以内。在后续的回溯性欠采样操作上, 我们使用了二维随机欠采样方式。

表 3.1 GAP-Net 在不同欠采样率下的定量分析。

Table 3.1 Quantitative analysis of the GAP-Net at different undersampling rates.

	4x	6x	8x	10x
PSNR	40.323	36.867	36.219	34.317
SSIM	0.96885	0.95106	0.94025	0.91576

我们在几种不同的欠采样率下进行了本章节所提方法重建性能的验证，其在测试集下的定量指标如表 3.1 所示。从该表中可以看出，所提方法在不同欠采样率下均能实现高质量的图像重建结果。随着欠采样率的不断提升，频域信息丢失得也越来越多，从欠采样图像中恢复出原始图像的难度也逐渐变大，所提方法的重建性能也受此影响降低，然而，总体而言，其图像重建质量变化不大，说明所提方法能够实现稳定的重建效果。

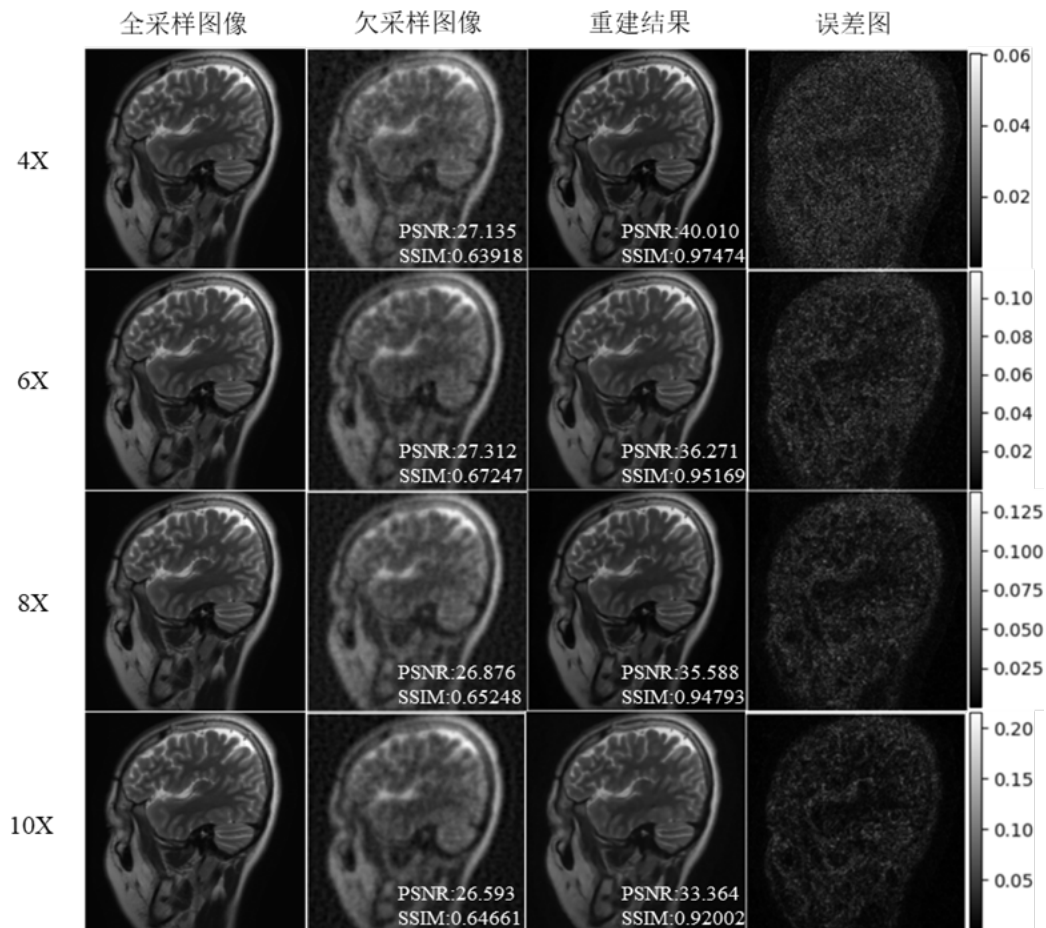


图 3.3 GAP-Net 在不同欠采样率下的定性分析。

Figure 3.3 Qualitative analysis of the GAP-Net at different undersampling rates.

图 3.3 为具体的可视化效果，反映了所提方法在不同欠采样率下的定量指标，

从该图中可以看出,方法的重建结果在 4 倍低欠采样率下,与原始图像之间的像素值差异较小,最高仅为 0.06,在 10 倍高加速倍数下,最大差异值也仅为 0.2,峰值信噪比 (Peak Signal to Noise Ratio, PSNR) 能够达到 33.364,结构相似度 (Structural Similarity Index Measure, SSIM) 能够达到 0.92002,这表明了所提方法在高欠采样率下依然能够实现高质量的图像重建。

为了更好地验证本章节所提方法的有效性,我们将其与其他几种基于深度学习的重建方法进行了对比实验。1) U-Net: 该方法属于深度学习中基于非迭代展开网络的重建方法,其具有 U 型的网络结构,在本实验中,所使用的 U-Net 网络模型具有 3 个下采样以及 3 个上采样操作,网络最深的通道数为 512;2) MoDL: 该方法属于深度学习中基于迭代展开网络的重建方法,以 CNN 作为去噪器充当数据先验,通过迭代的方式对 MRI 重建逆问题进行求解,本实验中迭代次数设置为 6,不同迭代过程中的网络参数进行了共享;3) GAP-Net / wo acc, 该方法为本章节所提方法的一个消融实验,根据公式 3.5 进行原变量 x 的更新,没有对其进行加速的过程;4) GAP-Net, 该方法则为本章节所提重建方法,与第 3 种实验设置不同,我们加速了对原变量 x 的更新过程,即使用公式 3.6 更新原变量 x 。我们将这几种方法在测试集上的定量指标表示于表 3.2,从该表中可知,在 8 倍欠采样率下,无论是否加速原变量 x 的更新过程,所提方法的磁共振图像重建质量均要优于 U-Net 以及 MoDL,在不加速的情况下,方法所实现的重建性能与 MoDL 相差不大,PSNR 相差 0.937,SSIM 相差 0.01421,而在对原变量 x 更新过程进行加速的情况下,所提方法的图像重建质量相较于 MoDL 有了明显的改善,PSNR 相差 2.174,SSIM 相差 0.02658。从相关实验结果中可以看出,我们所提的重建方法能够实现更高的图像重建质量,并且,即使在高欠采样率下,也能够实现稳定的重建效果。

表 3.2 不同方法在 8 倍欠采样率下的定量分析。

Table 3.2 Quantitative analysis of the different methods at 8-fold undersampling rates.

	U-Net	MoDL	GAP-Net w/o acc	GAP-Net
PSNR	33.303	34.045	34.982	36.219
SSIM	0.86862	0.91367	0.92788	0.94025

3.4 本章小结

本章节中，我们提出了一种将 GAP 算法与深度学习进行结合的磁共振图像重建方法，取名为 GAP-Net。该方法从 MR 物理模型出发，通过 GAP 算法迭代求解非线性优化问题，通过将 GAP 算法求解 MRI 重建逆问题的迭代步骤中的图像稀疏变换域、迭代步长以及收缩阈值等其他自由参数替换为深度学习中的卷积神经网络以及可学习参数，通过端到端的训练完成网络模型参数的优化过程，从而实现高质量的 MR 图像重建。所提方法隶属于深度学习中的基于迭代展开网络的重建方法，相较于传统 CS 算法，该方法无需人为经验性的设置参数，可以离线计算因而推理速度较快，而相较于深度学习中基于非迭代展开网络的重建方法而言，该方法具有数学可解释性强以及训练阶段所需样本少的优点。相关实验表明所提方法能够实现高质量的 MR 图像重建，与对比实验方法相比，能够恢复更多的图像细节信息。

第4章 基于自监督学习的MRI重建方法

4.1 引言

近些年来,基于深度学习的方法在MRI重建任务中已经取得了非常可观的效果。如前所述,这些方法大致上可分为以下两类:基于非迭代展开网络的重建方法以及基于迭代展开网络的重建方法。前者可表示为直接训练一个深度神经网络去学习从欠采样 k 空间数据/伪影图像到全采样 k 空间数据/无伪影图像的非线性映射函数,其中典型的工作有U-Net、GANCS以及KIKI-Net等。而基于迭代展开网络的重建方法则是根据CS算法迭代展开形式来构建网络结构,其中具有代表性的工作有ADMM-Net、VN-Net、ISTA-Net以及MoDL等。无论是上述方法中的哪一种,大多数现有的基于深度学习的MRI重建方法都依赖于全采样的MR原始数据来监督网络模型的整个优化过程。然而,由于成像对象生理条件或者MRI扫描设备物理条件上的限制,在许多成像场景中是很难获得全采样的数据,这就限制了基于深度学习的方法在MRI重建中的应用。最近,Yaman等人(Yaman et al., 2020)提出一种基于自监督学习的方法用以解决传统深度学习在网络模型训练阶段对全采样 k 空间数据的依赖性问题,称之为SSDU。该方法将欠采样到的 k 空间数据分为两个不相交的子集,其中一个子集的 k 空间数据用以作为深度神经网络的输入,另一个子集的数据则作为定义损失函数去约束网络参数的优化过程。尽管该方法取得了不错的自监督图像重建效果,其中依然存在着两个问题没有解决。首先,该方法中对两个 k 空间数据子集的划分需要谨慎地处理,当用于作为定义损失函数的子集中 k 空间数据采样点较少时,则对网络参数的优化过程约束性会降低,因此,网络的训练过程将可能会变得不稳定,网络的图像重建性能也会降低,在输出图像中可能会存在着不存在的伪影或者未去除干净的噪声。其次,该方法没有对未采样到的频率点信息作出任何约束,而这些频率点处的信息对恢复图像的整体或者局部细节信息也具有很重要的意义,因此,该方法无法保证深度神经网络最终输出的重建图像是预期的高质量图像,且其重建结果存在着较高的不确定性。

为了解决上述所提到的问题,本章节中根据 k 空间数据可分性以及欠采自相

同切片理应重建出相同图像这一特性提出了一种基于 MR 物理模型的自监督图像重建框架。其中,不同的是,我们从欠采样 k 空间数据中随机选取部分数据构造两个子集,然后将它们输入构建好的两个并行网络之中。相似的,我们利用了所有的欠采样数据去定义两个重建损失函数,即在所有欠采样频率点处计算重建损失,以此提高深度神经网络恢复频率信息的能力,并确保模型能够实现稳定的网络参数优化过程。除此之外,我们在两个并行分支网络的输出之间引入了一个差异损失,作为对未采样频率点处信息的一种间接的、合理的约束,以更好地帮助模型在测试阶段中后续的高质量图像重建。而在测试阶段,我们将所有获得的欠采样 k 空间数据作为并行网络分支之一的输入用以实现图像重建。

4.2 方法论

理论上,本章节所提方法可以与现有的任何一种基于深度学习的方法进行结合以实现自监督图像重建。基于迭代展开网络的重建方法具有可解释性较强,参数量少以及所需训练样本少的优点,因此这种方法在 MRI 重建中应用较为广泛,ISTA-Net 就是其中的一种重建方法,本章节便以 ISTA-Net 为例讲解如何使用我们提出的网络训练框架进行 MR 图像自监督重建。

4.2.1 ISTA-Net 概述

自将 CS 理论应用于 MRI 重建任务中,便可利用一些 CS 算法去迭代求解 CS-MRI 模型中的非线性优化问题。ISTA 就是一种较为流行的一阶近端方法,适合于求解许多逆问题。ISTA-Net 则是 Zhang 等人(Zhang and Ghanem, 2018)于 2018 年在计算机视觉领域知名会议 CVPR 上提出来的一种基于 ISTA 迭代展开版本的 MRI 重建方法,在该方法中,CS-MRI 模型中的正则化项被特定为 L_1 范数。ISTA-Net 通过交替进行以下两个步骤求解图像重建中的非线性逆问题:

$$r^{(k)} = x^{(k-1)} - \rho A^T (Ax^{(k-1)} - y) \quad \dots (4.1)$$

$$x^{(k)} = \tilde{\mathcal{F}} \left(\text{soft}(\mathcal{F}(r^{(k)}), \theta) \right) \quad \dots (4.2)$$

其中, x 为重建图像, A 表示为 MRI 成像中的编码矩阵, y 表示为欠采样 k 空间数据, k 表示为当前迭代次数, ρ 表示为步长, $\mathcal{F}(\cdot)$ 表示为一种通用的图像变换形式,

而 $\tilde{\mathcal{F}}(\cdot)$ 则表示其相对应的左逆, $\text{soft}(\cdot)$ 为软阈值操作, θ 为阈值。在 ISTA-Net 中, 图像变换 $\mathcal{F}(\cdot)$ 是通过神经网络实现的, 而 $\tilde{\mathcal{F}}(\cdot)$ 则具有和 $\mathcal{F}(\cdot)$ 相对称的网络结构。步长 ρ , 软阈值 θ 以及其他所有的自由参数都可以通过对神经网络的端到端训练得以优化。

ISTA-Net⁺是根据 ISTA-Net 的网络结构所改进而来的, 其通过增加残差连接的方式使得整个网络模型更加容易收敛, 在 MR 图像重建性能上也要优于 ISTA-Net, 因此, 本章节使用的网络模型为 ISTA-Net⁺。其第 k 个迭代步骤的网络结构图可由下图所示:




图 4.1 ISTA-Net⁺第 k 个迭代步骤的网络结构图(Zhang and Ghanem, 2018)。

Figure 4.1 The network architecture of the k -th phase of the ISTA-Net⁺(Zhang and Ghanem, 2018).

首先, 通过第一个迭代公式由 $x^{(k-1)}$ 得到 $r^{(k)}$, 此时特征图通道数为 1, 之后通过一层卷积层提取特征, 卷积之后的输出特征图通道数为 32, 即 $N_f = 32$, 将此作为非线性变换 $\mathcal{H}^{(k)}$ 的输入特征, 其中, $\mathcal{H}^{(k)}$ 用两层卷积层 (Conv + ReLU + Conv) 的操作进行表示, 然后将卷积之后得到的特征图进行软阈值操作, 随后通过与 $\mathcal{H}^{(k)}$ 具有相同网络结构的 $\tilde{\mathcal{H}}(\cdot)$, 得到输出特征图 $\mathcal{G}^{(k)}$, 此时的特征图通道数为 32, 之后通过一层卷积层输出通道数为 1 的输出特征图, 然后将此结果与 $r^{(k)}$ 做一个残差连接, 使得网络的梯度能够更好的传播, 有利于网络参数的优化, 残差连接的输出则作为最终更新得到的 $x^{(k)}$ 。ISTA-Net⁺的交替重建过程如上述所进行, 其中, 网络的初始化输入为欠采样图像, 即 $x^0 = F^{-1}y$, 网络最后一个迭代过程的输出则作为整个模型最终的重建图像, 每个迭代步骤中的网络参数以及可学习参数都可以通过在网络重建图像与原始图像之间作损失进行误差反向传播得以优化。

4.2.2 自监督学习框架

本章节所提自监督 MRI 重建框架图如下所示，其中包含两个阶段，一个只用欠采样 k 空间数据监督进行网络参数优化的训练阶段和一个从欠采样 k 空间数据中重建高质量图像的测试阶段。

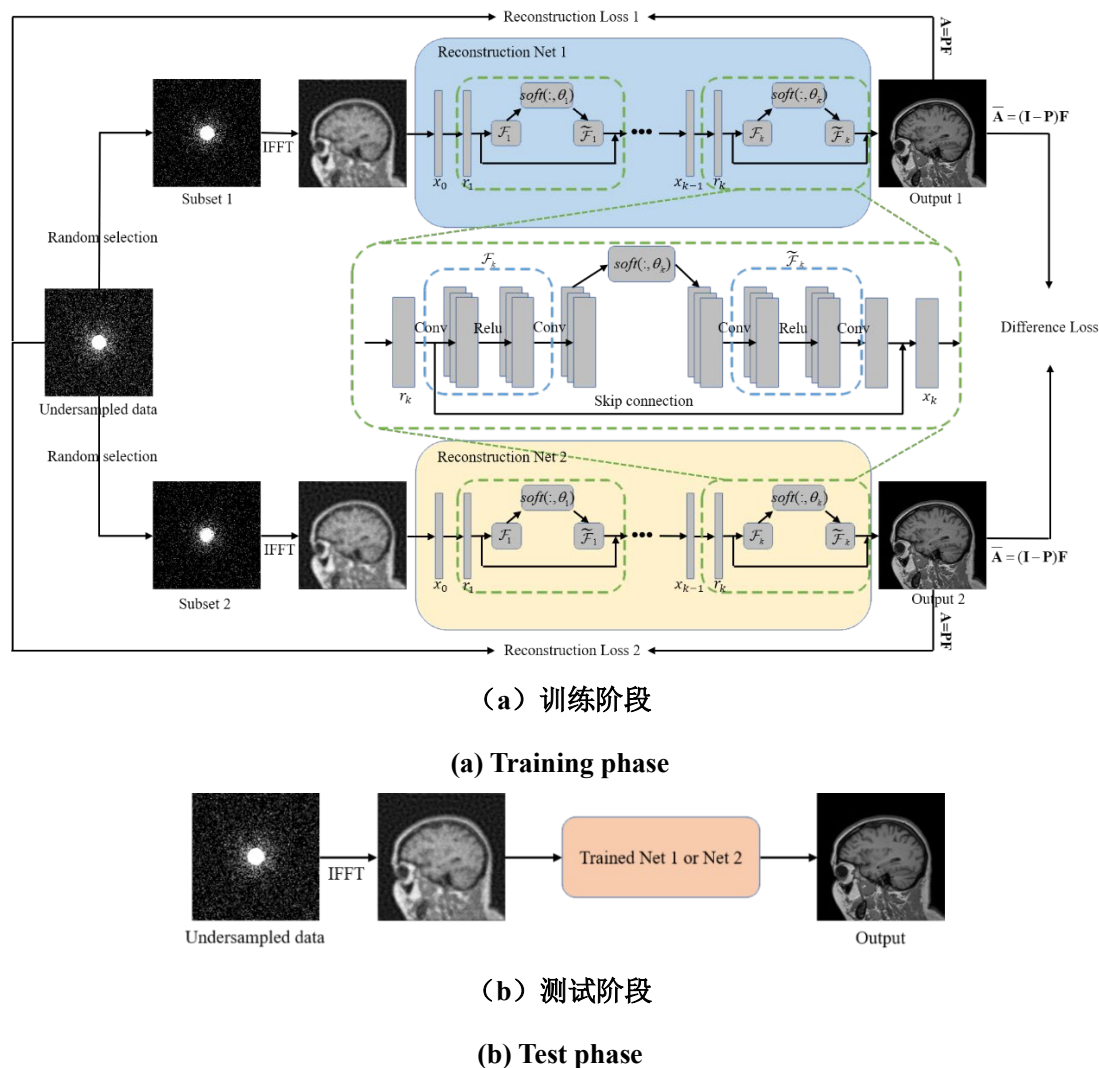


图 4.2 所提自监督 MRI 重建框架图。

Figure 4.2 The pipeline of our proposed framework for self-supervised MRI reconstruction.

在训练阶段，我们通过在欠采样 k 空间数据中进行随机选取的方式构成两个数据子集，然后将这两个子集作为输入分别送入构建好的并行网络的两个重建分支网络之中，本章节所使用的重建网络模型为 ISTA-Net⁺，其网络结构图如图 4.1 所述，迭代重建次数 k 设置为 9。如图 4.3 所示，我们通过在欠采样矩阵与选择矩阵之间取交集的方式来构造这两个子集，其中，欠采样矩阵的 ACS 区域半径为

24, 而选择矩阵的ACS区域半径为16, 在回顾性欠采过程和子集的构建过程中, 我们均采用了二维随机欠采样矩阵, **up** 和 **down** 分别表示并行网络的重建上分支网络与重建下分支网络。选择矩阵的选取是开放性的, 没有固定唯一的标准, 我们的实验初步表明选择矩阵的选取方式会对并行网络自监督重建性能有一定的影响, 以下是我们在选择选择矩阵时给出的经验性建议: 1) 并行网络两个重建分支中所使用的选择矩阵应该是独立不相同的。因为我们期望两个分支网络可以利用不同的信息进行重建, 并且重建出来的图像还保持一致; 2) 构建完成的子集应该包括欠采样 k 空间数据中的大部分低频信息以及部分高频信息。低频通常是图像的整体信息, 而高频则代表着图像的局部细节信息, 我们期望网络能够清楚输入的是什么图像, 并且在一些细节上也有所了解; 3) 子集的数据点数应该大约为欠采样数据点数的一半。如何控制二次欠采样的点数可以视之为一个 **trade-off** 的问题, 当网络的输入占据欠采样 k 空间数据的极少数时, 网络可能对图像的信息了解太少, 从中提取到的特征也不丰富, 而当网络的输入占据极多数时, 期望网络恢复的频率点信息就相应地变少了, 这对激励网络进行频率点信息恢复起到了一个负面的影响。

如图4.2所示, 在网络参数的优化过程中, 我们通过计算并行网络的两个重建分支输出的重建图像在欠采样频率点处与欠采样 k 空间数据之间的差异得到两个重建损失项, 并且, 针对这两个重建分支网络的输出, 我们还计算了它们在没有采样到的频率点处的差异, 定义为差异损失项, 这三个损失函数的线性加权求和作为整个网络最终的损失函数, 并且通过梯度反向传播算法优化并行网络中的可学习参数。其中, 计算差异损失项是作为对未采样频率点处信息的一种间接的、合理的约束, 其目的是期望两个重建分支网络最终重建的图像保持一致, 因为一个好的、鲁棒性高的重建方法从不同欠采自相同切片的欠采样 k 空间数据中应当恢复出相同的, 与真实原始图像保持一致的重建图像。因此, 本章节所提方法的训练阶段可以视之为解决以下的非线性优化问题:

$$\operatorname{argmin}_{x_1, x_2} \frac{1}{2} \|A_1 x_1 - y_1\|_2^2 + \frac{1}{2} \|A_2 x_2 - y_2\|_2^2 + \lambda \mathcal{R}(x_1) + \mu \mathcal{R}(x_2) + \nu \mathcal{L}(x_1, x_2) \quad \dots (4.3)$$

其中, y_1 和 y_2 是从欠采样 k 空间数据中随机选取的两个 k 空间数据子集, A_1 和 A_2 是相应的编码矩阵, x_1 和 x_2 是两个重建分支网络的输出图像, 两者均是真实原始

图像 x 的估计并且理论上应该保持一致。 $\mathcal{R}(\cdot)$ 为相应的正则化项， $\mathcal{L}(\cdot)$ 表示为某种相似性衡量指标， λ ， μ 以及 ν 为正则化系数，用以不同项之间的平衡。

由于我们在训练阶段定义三个损失项可以保证两个重建分支网络输出图像的一致性，因此为了减少测试阶段所需的计算量以及内存空间，在测试阶段，我们将采样得到的全部欠采样 k 空间数据送入并行网络的任一个重建分支网络中完成高质量的 MR 图像重建，此时训练好的网络应该具备良好的泛化性能并能够对缺失的 k 空间频率点信息进行推理恢复。




图 4.3 两个子集的构造。

Figure 4.3 Construction of the two subsets.

4.2.3 实现细节

所提方法训练时采用的整体损失函数可表示为：

$$\mathcal{L}(\Theta) = \frac{1}{N} \left(\sum_{i=1}^N \mathcal{L}(y^i, A^i x_1^i) + \sum_{i=1}^N \mathcal{L}(y^i, A^i x_2^i) + \alpha \sum_{i=1}^N \mathcal{L}(\bar{A}^i x_1^i, \bar{A}^i x_2^i) + \beta \mathcal{L}_{cons1} + \gamma \mathcal{L}_{cons2} \right) \dots (4.4)$$

其中， N 表示为训练数据集中切片的总数， i 表示第 i 个切片。 $x_k = f(y_k, A_k; \theta_k)$, $k = 1, 2$ ，其中， $f(\cdot)$ 表示为网络参数为 θ 的图像重建分支网络。 $A = PF$ 以及 $\bar{A} = (I - P)F$ 分别表示选取欠采样 k 空间频率点处信息以及没有采样到的频率点处信息用于计算重建损失项以及差异损失项。 \mathcal{L}_{cons} 表示为 ISTA-Net 文中定义的对称约束损失项，其目的是保证网络学习到的图像变换 $\mathcal{F}(\cdot)$ 满足对称约束，即 $\tilde{\mathcal{F}} \circ \mathcal{F} = I$ 。 α ， β 以及 γ 是正则化系数。本章节实验中，相似性衡量指标 $\mathcal{L}(\cdot)$ 特定为 MSE， $\alpha = \beta = \gamma = 0.01$ 。

本章节所提方法用深度学习框架 PyTorch 实现。网络模型的参数用 Xavier 中的方法进行初始化，其中的 $gain = 1$ 。为了更好地训练所构建的并行网络，我们

使用了学习率预热策略（学习率从 0 逐步增加，共 10 个 epoch 并在最后一个 epoch 时学习率为 0.0001），最小批次设置为 4，梯度反向传播时网络的参数使用 Adam 优化准则进行优化。当通过损失函数计算的损失在验证集上趋于稳定时，我们将学习率以一个固定比例 0.3 进行自动降低，以免网络参数优化过程中损失出现震荡的情况。本章节中所有实验都是在装配有两张英伟达 RTX 2080 Ti（显存为 11 GB）的 64 位 Ubuntu 18.04 LTS 操作系统上进行的。

所提自监督重建方法在 8 倍欠采样率下的网络损失曲线如图 4.4 所示，其中，横坐标为训练数据集的训练次数，纵坐标为计算得到的损失值，蓝色曲线代表在训练集上的损失曲线，红色曲线代表在验证集上的损失曲线。从图 4.4 中可以看出，训练损失曲线与验证损失曲线比较贴合，这说明训练过程中没有出现拟合或者欠拟合的异常训练情况，两种损失曲线都在稳步下降并且逐渐达到收敛状态，说明所提方法能够实现稳定的自监督训练过程，实现高质量的图像重建质量。

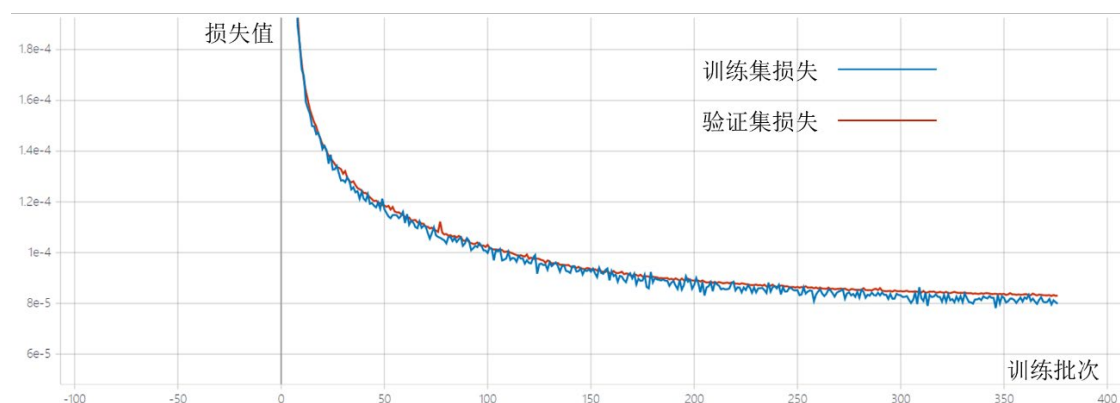


图 4.4 所提自监督重建方法在 8 倍欠采样率下的网络损失曲线。

Figure 4.4 The network loss curves of the proposed self-supervised reconstruction method at 8-fold undersampling rate.

4.3 实验结果与分析

数据集：本章节实验中所采用的数据集为公开数据集，Information eXtraction from Images (IXI)，该数据集收集自伦敦的三家医院。对于每个成像对象，均有其对应的 T1 对比度，T2 对比度，PD 加权，MRA 以及弥散加权图像。更多的信息比如扫描参数等可以在其官网 (<http://brain-development.org/ixi-dataset/>) 上进行查阅。本章节实验中采用的是从脑部 T1 对比度 MR 图像中得到的二维切片，其图像尺寸为 256×256 。其中，训练集，验证集以及测试集涉及到的切片总数分别

为 850, 250 以及 250。在进行回顾性欠采样操作之前, 我们将图像的幅值规范化至 $[0, 1]$ 区间之内。

对比实验: 为了更好地验证本章节所提方法的有效性, 我们将其与以下几种 MR 图像重建方法进行了对比: 1) U-Net-256: 该方法属于基于非迭代展开网络的重建方法中一种典型的 MR 重建方法, 具有与 U-Net 相同的 U 型网络结构, 但是网络的最深通道数仅为 256, 网络用全采样图像进行监督训练。2) SSDU: 该方法属于自监督重建方法, 为了进行更好的比较, 该方法采用了与本章节相同的网络模型 ISTA-Net⁺。为了保证网络训练的稳定性, 我们在网络损失函数的定义中额外利用了部分用于作为网络输入的 k 空间数据。3) Supervised: 该方法采用的网络模型为 ISTA-Net⁺, 用全采样图像进行监督训练, 其作为所提方法的对应的监督对比实验, 目的是为了让我们知道所提自监督方法重建性能与对应的监督训练方法相差几何, 对所提方法自监督重建性能有一个更加直观的了解。

表 4.1 不同重建方法在 4 倍和 8 倍欠采样率下的定量分析。

Table 4.1 Quantitative analysis of the different methods at two acceleration rates (4 and 8).

方法	PSNR		SSIM	
	4x	8x	4x	8x
U-Net-256	30.833	29.252	0.89184	0.85748
SSDU	35.908	32.469	0.95130	0.91531
Ours	38.575	33.255	0.97177	0.92709
Supervised	39.471	33.928	0.97843	0.93919

表 4.1 为不同重建方法在 4 倍和 8 倍欠采样率下的定量分析。PSNR 表示为峰值信噪比, SSIM 表示为结构相似性指数。从该表中可知, 与 U-Net-256 以及 SSDU 相比, 我们的方法在两种不同欠采样率下均实现了重建质量上显著的提升, PSNR 和 SSIM 两种图像质量评价指标都比这两种对比方法要高, 并且, 所提自监督方法能够实现与基于相同网络模型全采样图像监督训练方法相当的 MR 图像重建质量, 在 4 倍欠采样率下, 两者 PSNR 相差 0.896, SSIM 相差 0.00666, 而在 8 倍欠采样率下, PSNR 相差 0.673, SSIM 相差 0.0121。图 4.5 展示了不同方法实现的实例重建结果及其相应的误差图, 从误差图中可以直观的看出, 与 U-Net-256 和 SSDU 这两种方法相比, 本章节所提方法能够恢复出更多的图像细节,

重建图像的噪声也要比较小,这表明我们的方法可以重建出具有更好视觉质量的MR图像,而与对应的监督方法相比,所提方法的重建结果与其差距很小,对一些图像细节上的恢复效果相当,从红色箭头所指示的地方便可以直观地看出这点。

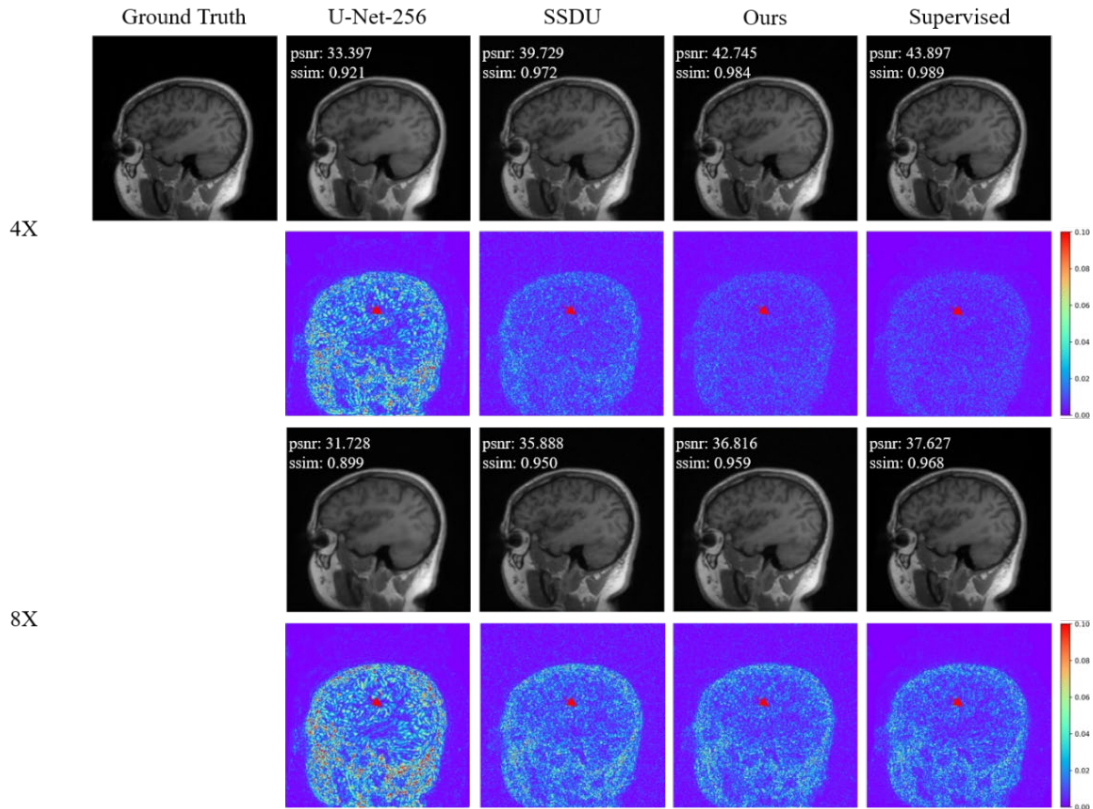


图 4.5 不同方法在 4 倍和 8 倍欠采样率下的实例重建结果及误差图。

Figure 4.5 Example reconstruction results of the different methods at two acceleration rates (4 and 8) along with their corresponding error maps.

消融分析:为了更好的验证所提方法不同组成部分的有效性,我们进行了消融实验并将其结果展示在表 4.2 中,其中,wo DiffLoss 表示没有用到所提出的差异损失项,即没有对未欠采样 k 空间频率点处的信息作出任何约束,share 和 wo share 这两种方法都用到了定义差异损失项,两者的不同在于并行网络的两个重建分支网络的参数是否是共享的,share 表示共享,而 wo share 表示不进行共享。从表 4.2 中可以看出,wo DiffLoss 的效果要比 SSDU 要好,在 4 倍和 8 倍欠采样率下,前者的 PSNR 以及 SSIM 都要明显高于后者,这说明用更多的频率点信息定义损失函数项会对网络恢复频率信息起到一个正向的激励作用,并且,无论重建分支网络的参数是否进行共享,使用定义差异损失均会带来效果的提升,这说明该损失能够有效地限制解空间,改善网络的自监督重建性能,此外,不共

享参数实现的效果最好,这可能意味着参数不同,重建分支网络学到的信息不同,会更利于网络进行高质量的图像重建。

表 4.2 4 倍与 8 倍欠采样率下的消融实验结果。

Table 4.2 Ablation study results at two acceleration rates (4 and 8).

方法	PSNR		SSIM	
	4x	8x	4x	8x
SSDU	35.908	32.469	0.95130	0.91531
Self-supervised w/o DiffLoss	38.054	33.077	0.97036	0.92439
Self-supervised / share	38.353	33.216	0.97086	0.92681
Self-supervised w/o share (Ours)	38.575	33.255	0.97177	0.92709

4.4 本章小结

本章节中,我们根据 k 空间数据可分性以及欠采自相同切片理应重建出相同图像这一特性提出了一种基于 MR 物理模型的自监督图像重建框架,理论上,该框架可以应用于任何现有的基于深度学习的重建方法中以实现 MR 图像自监督重建。其通过二次欠采样操作以及并行网络框架的设计,利用重建损失项与差异损失项将输出图像的损失计算于全部 k 空间频率点处,使得构建的神经网络具有从已知 k 空间频率点信息中推理出未知频率点信息的能力,并且对没有采样到的 k 空间频率点处的信息作出了一种间接的、合理的约束,进一步限制了网络的解空间,以更好地帮助模型在测试阶段中后续的高质量图像重建。利用我们提出的自监督学习方法,可以使得网络模型中的参数在不使用任何全采样 k 空间数据的情况下得以优化,从而重建出高质量的 MR 图像,这可以有效解决传统基于深度学习的重建方法在网络训练阶段对全采样 k 空间数据的依赖性问题。相关实验结果表明,本章节所提自监督重建方法在高欠采样率的情况下可以实现与相同网络模型监督训练方法相当的 MR 图像重建质量。

第5章 总结与展望

5.1 工作总结

MRI 是一种用于临床诊断和研究中不可或缺的成像技术,其具有无创、无辐射以及软组织对比度高的特点,可以实现多参数、多功能以及多角度成像,能够准确获取人体器官以及组织的生理功能和解剖结构。然而缓慢的成像过程限制了其在临床上的进一步应用,实现快速 MRI 的一种常用方法是:先对 MR 数据以一个较高的欠采样率进行欠采,之后通过图像处理等技术进行重建,恢复出高质量的图像。但是高欠采样率会导致图像出现伪影以及噪声放大的情况,并且会使得 MRI 重建逆问题变得病态欠定。因此,如何从欠采样 k 空间数据中进行高质量的图像重建是一项意义重大但充满挑战的任务。目前基于深度学习的重建方法在 MRI 领域被广泛研究,其中大多数方法仅通过训练一个神经网络去拟合从欠采样数据到全采样数据的非线性映射函数,忽略了 MRI 特有的成像方式,没有考虑到 MR 物理模型,因此,方法的重建性能以及泛化性有待提高。

本文提出了一种基于迭代展开网络的磁共振图像重建方法,该方法从 MR 物理模型出发,通过 GAP 算法迭代求解非线性优化问题,将 GAP 算法求解 MRI 重建逆问题的迭代步骤中的图像稀疏变换域替换为深度学习中的 CNN,将迭代步长以及收缩阈值设置为可学习参数,实现 GAP 算法与深度学习的结合。与传统 CS 算法应用于 MRI 重建任务中不同,所提方法无需人为经验性地假定图像稀疏变换域以及设置迭代步长等自由参数,并且由于可离线计算,其推理速度也相较更快。相较于基于非迭代展开网络的重建方法而言,所提方法具有一定的数学可解释性,能够实现较高稳定性的图像重建,不需要大量的训练集样本便可完成对网络模型的训练过程。

除此之外,本文还根据 k 空间数据可分性以及欠采自相同切片理应重建出相同图像这一特性提出了一种基于 MR 物理模型的自监督图像重建框架,理论上,该框架可以应用于目前任何一种基于深度学习的重建方法中以实现 MR 图像自监督重建,能够有效解决传统深度学习方法在网络模型训练阶段对全采样 k 空间数据的依赖性问题。通过以欠采样 k 空间数据子集恢复全部欠采样 k 空间数据的

方式促进网络学习恢复频率点信息的能力，并且，通过并行网络框架的构建以及对两个分支重建网络输出图像作出的一致性约束项对没有采集到的频率点信息施加一个间接而有效的约束，以此提升所提方法的图像自监督重建质量。初步的实验表明所提方法在高欠采样率下能够实现与相同网络模型监督学习的重建方法相当的 MR 图像重建质量。

5.2 工作展望

在本文中，我们提出了两种基于 MR 物理模型和深度学习的 MRI 重建方法以实现更高的图像重建质量或者解决网络训练阶段过程中对全采样 k 空间数据的依赖性问题，虽然取得了一定的成果，然而其中也存在着些许不足，需要进一步改善。在 GAP-Net 这项工作中，我们或许可以适当地放松条件，将辅助变量更新这个图像去噪的步骤直接用一个去噪神经网络进行代替，更大程度上地发挥神经网络具有较强特征表达能力这一优越性，使得方法的重建性能得以进一步地改善。而在 MR 图像自监督重建这项工作中，我们可以通过设计更好的约束项去约束网络模型在未扫描频率点处的信息恢复过程，或者增强并行网络的两个分支重建网络之间的交互性以进一步提升方法的图像重建质量。

参考文献

- 黄佳佳 2014. 快速成像序列设计与伪影消除方法研究 [M]. 电子科技大学.
- EDELMAN R R, WIELOPOLSKI P, SCHMITT F 1994. Echo-planar MR imaging. Radiology [J], 192: 600-612.
- LISTERUD J, EINSTEIN S, OUTWATER E, et al. 1992. First principles of fast spin echo. Magnetic resonance quarterly [J], 8: 199-244.
- KAISER W, ZEITLER E 1989. MR imaging of the breast: Fast imaging sequences with and without Gd-DTPA. Preliminary observations. Radiology [J], 170: 681-686.
- 张久明 2014. 磁共振并行成像重建算法研究 [M]. 吉林大学.
- PRUESSMANN K P, WEIGER M, SCHEIDEGGER M B, et al. 1999. SENSE: Sensitivity encoding for fast MRI. Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine [J], 42: 952-962.
- GRISWOLD M A, JAKOB P M, HEIDEMANN R M, et al. 2002. Generalized autocalibrating partially parallel acquisitions (GRAPPA). Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine [J], 47: 1202-1210.
- LUSTIG M, PAULY J M 2010. SPIRiT: Iterative self-consistent parallel imaging reconstruction from arbitrary k-space. Magnetic resonance in medicine [J], 64: 457-471.
- 王水花, 张煜东 2015. 压缩感知磁共振成像技术综述. 中国医学物理学杂志 [J], 32: 158-162.
- DONOHU D L 2006. Compressed sensing. IEEE Transactions on information theory [J], 52: 1289-1306.
- LUSTIG M, DONOHU D, PAULY J M 2007. Sparse MRI: The application of compressed sensing for rapid MR imaging. Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine [J], 58: 1182-1195.
- WANG S, SU Z, YING L, et al. Accelerating magnetic resonance imaging via deep learning[C]//2016 IEEE 13th international symposium on biomedical imaging (ISBI).IEEE,2016:514-517.
- LAI Z, QU X, LIU Y, et al. 2016. Image reconstruction of compressed sensing MRI using graph-

- based redundant wavelet transform. Medical image analysis [J], 27: 93-104.
- QU X, GUO D, NING B, et al. 2012. Undersampled MRI reconstruction with patch-based directional wavelets. Magnetic resonance imaging [J], 30: 964-977.
- ZHU Z, WAHID K, BABYN P, et al. 2013. Compressed sensing-based MRI reconstruction using complex double-density dual-tree DWT. International Journal of Biomedical Imaging [J], 2013.
- BLOCK K T, UECKER M, FRAHM J 2007. Undersampled radial MRI with multiple coils. Iterative image reconstruction using a total variation constraint. Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine [J], 57: 1086-1098.
- YANG J, ZHANG Y, YIN W 2010. A fast alternating direction method for TVL1-L2 signal reconstruction from partial Fourier data. IEEE Journal of Selected Topics in Signal Processing [J], 4: 288-297.
- KNOLL F, BREDIES K, POCK T, et al. 2011. Second order total generalized variation (TGV) for MRI. Magnetic resonance in medicine [J], 65: 480-491.
- ZHAN Z, CAI J-F, GUO D, et al. 2015. Fast multiclass dictionaries learning with geometrical directions in MRI reconstruction. IEEE Transactions on biomedical engineering [J], 63: 1850-1861.
- CABALLERO J, PRICE A N, RUECKERT D, et al. 2014. Dictionary learning and time sparsity for dynamic MR data reconstruction. IEEE transactions on medical imaging [J], 33: 979-994.
- RAVISHANKAR S, BRESLER Y 2010. MR image reconstruction from highly undersampled k-space data by dictionary learning. IEEE transactions on medical imaging [J], 30: 1028-1041.
- RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical image computing and computer-assisted intervention.Springer,2015:234-241.
- MARDANI M, GONG E, CHENG J Y, et al. 2018. Deep generative adversarial neural networks for compressive sensing MRI. IEEE transactions on medical imaging [J], 38: 167-179.
- WANG S, CHENG H, YING L, et al. 2020. DeepcomplexMRI: Exploiting deep residual network for fast parallel MR imaging with complex convolution. Magnetic resonance imaging [J], 68: 136-147.
- SUN J, LI H, XU Z 2016. Deep ADMM-Net for compressive sensing MRI. Advances in neural

- information processing systems [J], 29.
- HAMMERNIK K, KLATZER T, KOBLER E, et al. 2018. Learning a variational network for reconstruction of accelerated MRI data. *Magnetic resonance in medicine* [J], 79: 3055-3071.
- ZHANG J, GHANEM B. ISTA-Net: Interpretable optimization-inspired deep network for image compressive sensing[C]//Proceedings of the IEEE conference on computer vision and pattern recognition.2018:1828-1837.
- AGGARWAL H K, MANI M P, JACOB M 2018. MoDL: Model-based deep learning architecture for inverse problems. *IEEE transactions on medical imaging* [J], 38: 394-405.
- BUSTIN A, FUIN N, BOTNAR R M, et al. 2020. From compressed-sensing to artificial intelligence-based cardiac MRI reconstruction. *Frontiers in cardiovascular medicine* [J], 7: 17.
- MAJUMDAR A 2013. Improved dynamic MRI reconstruction by exploiting sparsity and rank-deficiency. *Magnetic resonance imaging* [J], 31: 789-795.
- LINGALA S G, HU Y, DIBELLA E, et al. 2011. Accelerated dynamic MRI exploiting sparsity and low-rank structure: kt SLR. *IEEE transactions on medical imaging* [J], 30: 1042-1054.
- JUNG H, SUNG K, NAYAK K S, et al. 2009. k-t FOCUSS: A general compressed sensing framework for high resolution dynamic MRI. *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine* [J], 61: 103-116.
- TSAO J, BOESIGER P, PRUESSMANN K P 2003. k-t BLAST and k-t SENSE: Dynamic MRI with high frame rate exploiting spatiotemporal correlations. *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine* [J], 50: 1031-1042.
- ZHANG J, LIU H, TONG H, et al. 2017. Clinical applications of contrast-enhanced perfusion MRI techniques in gliomas: recent advances and current challenges. *Contrast media & molecular imaging* [J], 2017.
- PAULSON E S, PRAH D E, SCHMAINDA K M 2016. Spiral perfusion imaging with consecutive echoes (SPICE™) for the simultaneous mapping of DSC-and DCE-MRI parameters in brain tumor patients: theory and initial feasibility. *Tomography* [J], 2: 295-307.
- LAW M, YANG S, BABB J S, et al. 2004. Comparison of cerebral blood volume and vascular permeability from dynamic susceptibility contrast-enhanced perfusion MR imaging with glioma grade. *American Journal of Neuroradiology* [J], 25: 746-755.

- CHAARI L, CIUCIU P, MÉRIAUX S, et al. 2014. Spatio-temporal wavelet regularization for parallel MRI reconstruction: application to functional MRI. *Magnetic Resonance Materials in Physics, Biology and Medicine* [J], 27: 509-529.
- GINDI G, LEE M, RANGARAJAN A, et al. 1993. Bayesian reconstruction of functional images using anatomical information as priors. *IEEE transactions on medical imaging* [J], 12: 670-680.
- KNUDSEN H B, GELINECK J, SØBJERG J O, et al. 1999. Functional and magnetic resonance imaging evaluation after single-tendon rotator cuff reconstruction. *Journal of Shoulder and Elbow Surgery* [J], 8: 242-246.
- FEINBERG D A, HALE J D, WATTS J C, et al. 1986. Halving MR imaging time by conjugation: demonstration at 3.5 kG. *Radiology* [J], 161: 527-531.
- MCGIBNEY G, SMITH M, NICHOLS S, et al. 1993. Quantitative evaluation of several partial Fourier reconstruction algorithms used in MRI. *Magnetic resonance in medicine* [J], 30: 51-59.
- UECKER M, LAI P, MURPHY M J, et al. 2014. ESPIRiT—An eigenvalue approach to autocalibrating parallel MRI: where SENSE meets GRAPPA. *Magnetic resonance in medicine* [J], 71: 990-1001.
- XU D, KING K F, LIANG Z P 2007. Improving k-t SENSE by adaptive regularization. *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine* [J], 57: 918-930.
- HUANG F, AKAO J, VIJAYAKUMAR S, et al. 2005. k-t GRAPPA: A k-space implementation for dynamic MRI with high reduction factor. *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine* [J], 54: 1172-1184.
- GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. 2014. Generative adversarial nets. *Advances in neural information processing systems* [J], 27.
- KRIZHEVSKY A, SUTSKEVER I, HINTON G E 2012. Imagenet classification with deep convolutional neural networks. *Advances in neural information processing systems* [J], 25.
- SIMONYAN K, ZISSERMAN A 2014. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556* [J].
- HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*.2016:770-778.

- REN S, HE K, GIRSHICK R, et al. 2015. Faster r-cnn: Towards real-time object detection with region proposal networks. *Advances in neural information processing systems* [J], 28.
- AKÇAKAYA M, MOELLER S, WEINGÄRTNER S, et al. 2019. Scan-specific robust artificial-neural-networks for k-space interpolation (RAKI) reconstruction: Database-free deep learning for fast imaging. *Magnetic resonance in medicine* [J], 81: 439-453.
- EO T, JUN Y, KIM T, et al. 2018. KIKI-net: Cross-domain convolutional neural networks for reconstructing undersampled magnetic resonance images. *Magnetic resonance in medicine* [J], 80: 2188-2201.
- ZHU B, LIU J Z, CAULEY S F, et al. 2018. Image reconstruction by domain-transform manifold learning. *Nature* [J], 555: 487-492.
- YANG G, YU S, DONG H, et al. 2017. DAGAN: Deep de-aliasing generative adversarial networks for fast compressed sensing MRI reconstruction. *IEEE transactions on medical imaging* [J], 37: 1310-1321.
- CHENG J, WANG H, YING L, et al. Model learning: Primal dual networks for fast MR imaging[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention.Springer,2019:21-29.
- YAMAN B, HOSSEINI S A H, MOELLER S, et al. 2020. Self-supervised learning of physics-guided reconstruction neural networks without fully sampled reference data. *Magnetic resonance in medicine* [J], 84: 3172-3191.
- 金永君, 艾延宝 2002. 核磁共振技术及应用. 物理与工程 [J]: 47-48+50.
- ELMAOĞLU M, ÇELİK A. MRI handbook: MR physics, patient positioning, and protocols[C]//:Springer Science & Business Media,2011
- LIANG Z-P, LAUTERBUR P C. Principles of magnetic resonance imaging: a signal processing perspective[C]//:"The" Institute of Electrical and Electronics Engineers Press,2000
- HAMILTON J, FRANSON D, SEIBERLICH N 2017. Recent advances in parallel imaging for MRI. *Progress in nuclear magnetic resonance spectroscopy* [J], 101: 71-95.
- ZBONTAR J, KNOLL F, SRIRAM A, et al. 2018. fastMRI: An open dataset and benchmarks for accelerated MRI. *arXiv preprint arXiv:1811.08839* [J].
- LIAO X, LI H, CARIN L 2014. Generalized alternating projection for weighted-2,1 minimization with applications to model-based compressive sensing. *SIAM Journal on Imaging Sciences* [J],

7: 797-823.

YUAN X, LIU Y, SUO J, et al. Plug-and-play algorithms for large-scale snapshot compressive imaging[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition.2020:1447-1457.

BECK A, TEBOULLE M 2009. Fast gradient-based algorithms for constrained total variation image denoising and deblurring problems. IEEE transactions on image processing [J], 18: 2419-2434.

ZHU M, WRIGHT S J, CHAN T F 2010. Duality-based algorithms for total-variation-regularized image restoration. Computational Optimization and Applications [J], 47: 377-400.

YUAN X. Generalized alternating projection based total variation minimization for compressive sensing[C]//2016 IEEE International Conference on Image Processing (ICIP).IEEE,2016:2539-2543.

GLOROT X, BENGIO Y. Understanding the difficulty of training deep feedforward neural networks[C]//Proceedings of the thirteenth international conference on artificial intelligence and statistics.JMLR Workshop and Conference Proceedings,2010:249-256.

KINGMA D P, BA J 2014. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980 [J].

致 谢

本文是在王珊珊老师的耐心指导下完成的。王老师热爱科研、治学严谨，对于学科相关学术问题的发现具有敏锐的目光，在磁共振成像、医学图像分析以及人工智能等领域具有非常深厚的学术知识，对我研究方向的指导起到了非常重要的意义。王老师对待学生耐心指导，耐心解疑，注重学生的成长以及科研素养的培养，在王老师的悉心栽培下，我不仅积累了很多科研的经验，而且还提升了独立分析问题，解决问题的能力，这些都将使我受益匪浅。师者，所以传道授业解惑也，形容王老师一点也不为过。同时，我还要感谢我的第二导师王海峰老师，王海峰老师帮助我顺利地完成任务的开展，督促我按时完成课题进度，感谢王海峰老师的鞭策与关照。

感谢我的家人，感谢父母多年来的养育之恩以及无私的付出与支持，让我无忧无虑快乐地度过二十余载，形成正确的人生价值观，感谢我的哥哥以及嫂子对我的牵挂与关爱，在我迷茫的时候能够分享自己的经验给我指引方向，在我无助的时候能够给予我力所能及的帮助。再次由衷地感谢你们的亲情与关怀。

感谢实验室的同门：肖韬辉、薛珍珍、邹娟、李龙飞、杨瑞、陈艳霞、杨浩、黄纬键、吴若有、Yousuf、Aamir、彭振坤、梁皓云、李昌永、刘雪、张宇、李浩然、王晔绮、杨静、樊文欣、丛君殊、韩华。尤其感谢李程师姐在我英文论文写作以及投稿中给予我的无私帮助，感谢荣楚誉、龚宇、祁可翰师兄对我科研、生活以及工作上的帮助。在先进院的两年时光飞逝而过，与你们一起科研、一起生活，感谢你们让我的研究生生涯充实而快乐。

感谢医工所的郑海荣老师、梁栋老师以及刘新老师，感谢你们为医工所的发展作出的贡献，感谢你们无私的付出与关怀。

感谢影像中心以及教育处的倪舒婷老师、蔡叶老师、吴灿鑫老师、罗芳芳老师、谢昕老师、艾筱雯老师、王蕾老师、佟雪铭老师等，感谢你们在我学习与工作中提供的无微不至的帮助。

感谢所有曾经关心和帮助过我的人，你们的支持让我能够砥砺前行。

